TALLER 2: REDES NEURONALES

Sistemas Avanzados de Producción — Ingeniería Industrial

Capital Bikeshare — Washington D.C. (2011–2012)

Santiago Alfonso Aviles Buitrago
Haider Fabian Rodríguez Orjuela
Brayan Mauricio Toro

12 de Abril de 2026

1. Introducción

En el marco de las ciudades inteligentes (Smart Cities) y la movilidad sostenible, los sistemas de bicicletas compartidas se han consolidado como una red de sensores urbanos que genera datos continuos sobre patrones de movilidad. El conjunto de datos Capital Bikeshare registra el flujo horario de alquiler de bicicletas en Washington D.C. durante los años 2011 y 2012, integrando información meteorológica, estacional y temporal.

Para un Ingeniero Industrial, predecir con precisión esta demanda representa un reto de optimización logística: un exceso de bicicletas en una estación genera costos de almacenamiento y subutilización, mientras que una escasez provoca pérdida de clientes y fallos en el servicio de transporte multimodal. La variable objetivo es cnt — el total de bicicletas alquiladas por hora, sumando usuarios casuales y registrados.

Este informe recorre cinco fases metodológicas: (1) fundamentación matemática de la regularización Ridge, (2) exploración del descenso de gradiente como motor de optimización, (3) implementación de un Perceptrón Multicapa con ajuste de hiperparámetros, (4) propagación hacia adelante manual en una red de clasificación, y (5) evaluación de modelos con métricas orientadas al negocio de mantenimiento predictivo.

2. Fase 1: Desarrollo Analítico — Regularización Ridge

2.1 Motivación y Función de Costo

Cuando existe multicolinealidad entre predictores (como temperatura real atemp y temperatura percibida temp, con correlación de Pearson r ≈ 0.99 en este dataset), el estimador de Mínimos Cuadrados Ordinarios presenta varianza excesiva. La Regresión Ridge introduce una penalización L2 sobre la magnitud de los coeficientes para controlar el sobreajuste. La función de costo a minimizar es:

$$J(\beta) = \Sigma(y_i - \beta_0 - \Sigma_j \beta_j x_{ij})^2 + \lambda \Sigma_j \beta_j^2$$

Expresada en notación matricial — donde $X \in \mathbb{R}^{n \times (p+1)}$ es la matriz de diseño, $Y \in \mathbb{R}^n$ el vector de respuestas, $\beta \in \mathbb{R}^{p+1}$ el vector de parámetros e I la matriz identidad — la función de costo resulta:

$$J(\beta) = (Y - X\beta)^T(Y - X\beta) + \lambda \beta^T\beta$$

2.2 Derivación Matemática Paso a Paso

Paso 1 — Expansión de la Forma Cuadrática

Desarrollando el producto matricial del término de error:

$$(Y - X\beta)^T(Y - X\beta) = Y^TY - 2\beta^TX^TY + \beta^TX^TX\beta$$

Combinando con la penalización $\lambda\beta^T\beta$ y factorizando la identidad:

$$J(\beta) = Y^TY - 2\beta^TX^TY + \beta^T(X^TX + \lambda I)\beta$$

Paso 2 — Condición de Primer Orden (Gradiente)

Calculando el gradiente e igualando a cero:

- $\partial(\beta^TX^TY)/\partial\beta = X^TY$
- $\partial(\beta^T(X^TX + \lambda I)\beta)/\partial\beta = 2(X^TX + \lambda I)\beta$ [$X^TX + \lambda I$ es simétrica]

$$\partial J(\beta)/\partial\beta = -2X^TY + 2(X^TX + \lambda I)\beta = 0$$

Paso 3 — Solución Cerrada del Estimador Ridge

Despejando β de la ecuación normal regularizada:

$$\hat{\beta}Ridge = (X^TX + \lambda I)^{-1} X^TY$$

Cuando λ = 0 se recupera exactamente el estimador OLS: $\hat{\beta}OLS = (X^TX)^{-1}X^TY$, lo que demuestra que Ridge es una generalización coherente del modelo lineal clásico.

2.3 Superficies 3D: Ridge vs. Lasso

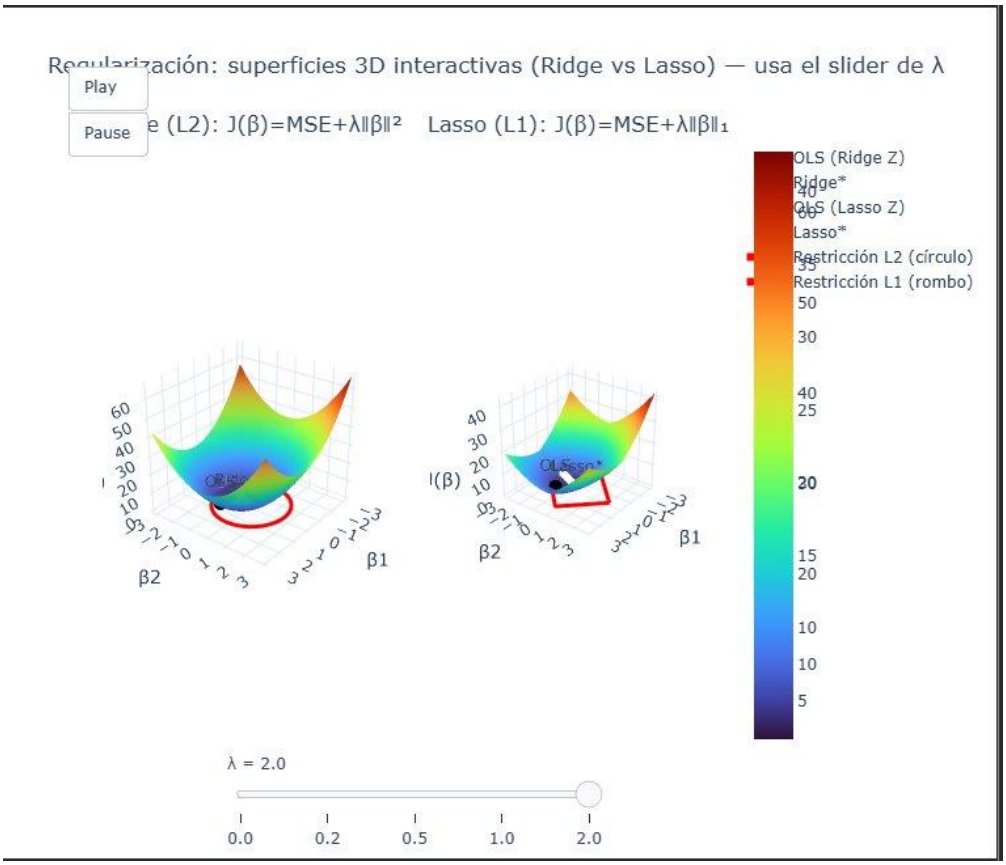

Figura 1. Superficies 3D de J(β) para Ridge (L2) y Lasso (L1) con λ = 2.0. La restricción L2 forma una esfera y la L1 un rombo, lo que induce sparsidad en Lasso al hacer tangencia en los vértices.

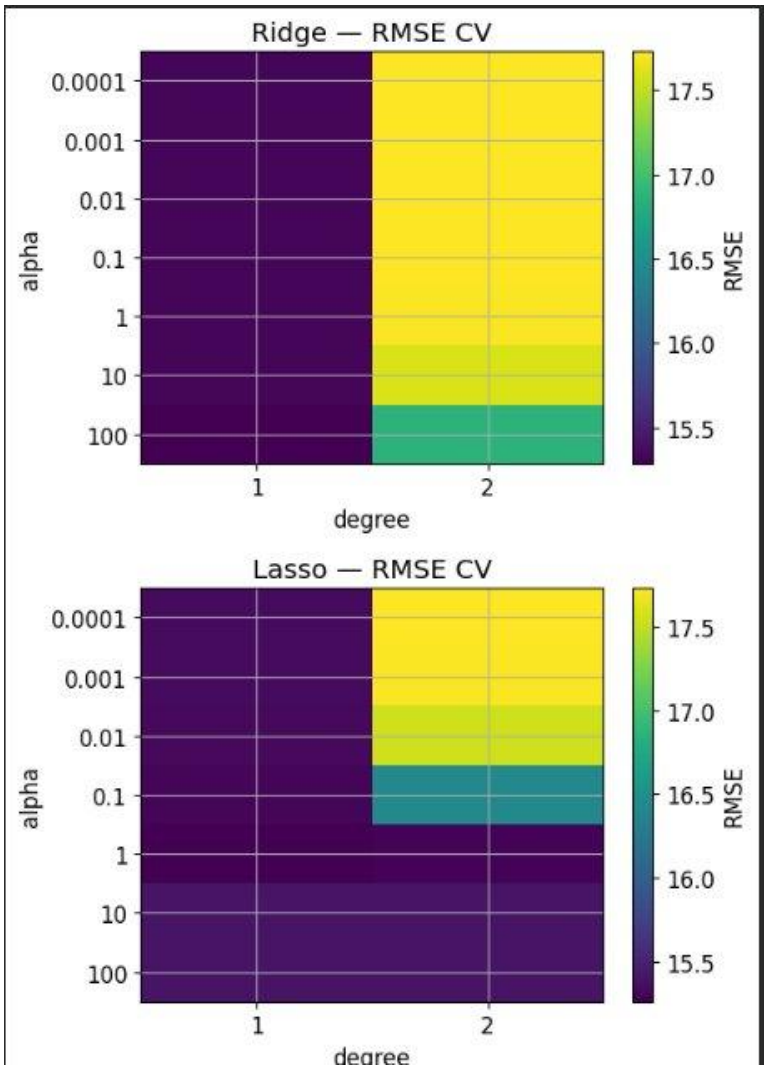

Figura 2. Heatmaps de RMSE en validación cruzada para Ridge y Lasso según alpha y grado polinomial. El mínimo RMSE (≈15.5) se alcanza con alpha > 1 en términos lineales (degree=1) para ambos modelos.

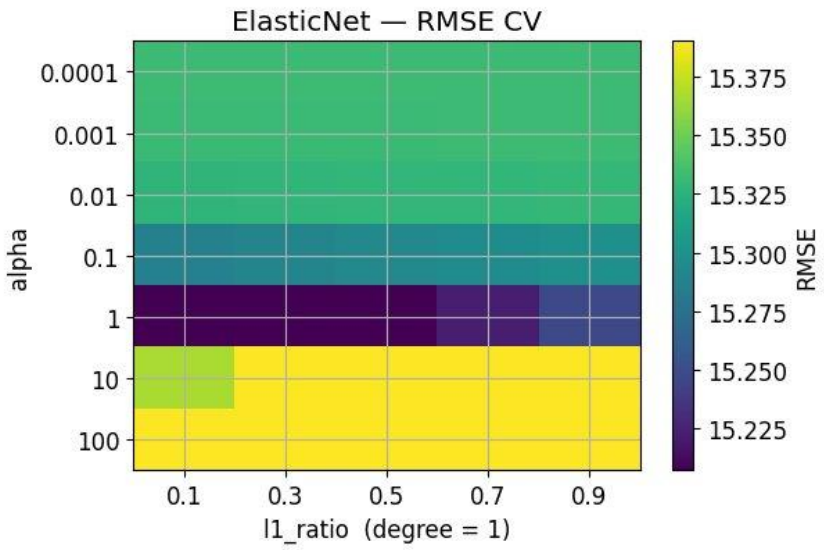

Figura 3. Heatmap RMSE para ElasticNet según alpha y l1_ratio. El mínimo RMSE (≈15.22) se logra con alpha ≈ 1 y l1_ratio bajo (predominio L2), confirmando que la regularización Ridge es más beneficiosa para este dataset.

2.4 Preguntas de Análisis

P1 — ¿Por qué λI garantiza la invertibilidad?

La matriz X^TX es semidefinida positiva y puede ser singular cuando existe multicolinealidad (como entre temp y atemp, $r \approx 0.99$) o cuando $p > n$. Al sumar λI con $\lambda > 0$, todos los valores propios pasan de $\lambda_i \geq 0$ a $\lambda_i + \lambda > 0$. Una matriz con todos sus valores propios estrictamente positivos es definida positiva y, por tanto, siempre invertible, garantizando una solución única βRidge.

P2 — Efecto del parámetro λ: sesgo vs. varianza

Escenario	Comportamiento del modelo	Implicación operativa
$\lambda \to 0$	βRidge converge al estimador OLS. Sesgo bajo, varianza alta. Riesgo de sobreajuste con predictores correlacionados.	El modelo memoriza ruido del historial y falla ante nuevas condiciones meteorológicas.
λ óptimo (≈1)	Equilibrio sesgo-varianza hallado por validación cruzada. Coeficientes moderados y estables. Confirmado por los heatmaps (Figuras 2-3).	Predicciones robustas para planificación logística de redistribución de flota.
$\lambda \to \infty$	Todos los coeficientes βRidge → 0. Varianza muy baja, sesgo alto. Subajuste severo.	El modelo ignora clima, hora y estación; predice siempre la media global de demanda.

3. Fase 2: Optimización Numérica — Descenso de Gradiente

3.1 Función de Himmelblau: Paisaje de Optimización

La función de Himmelblau $f(x,y) = (x^2 + y - 11)^2 + (x + y^2 - 7)^2$ presenta cuatro mínimos globales ($f = 0$) en (3,2), (−2.805, 3.131), (−3.779, −3.283) y (3.584, −1.848). Esta topografía multimodal la convierte en un benchmark ideal para estudiar las limitaciones del descenso de gradiente con punto de inicio único.

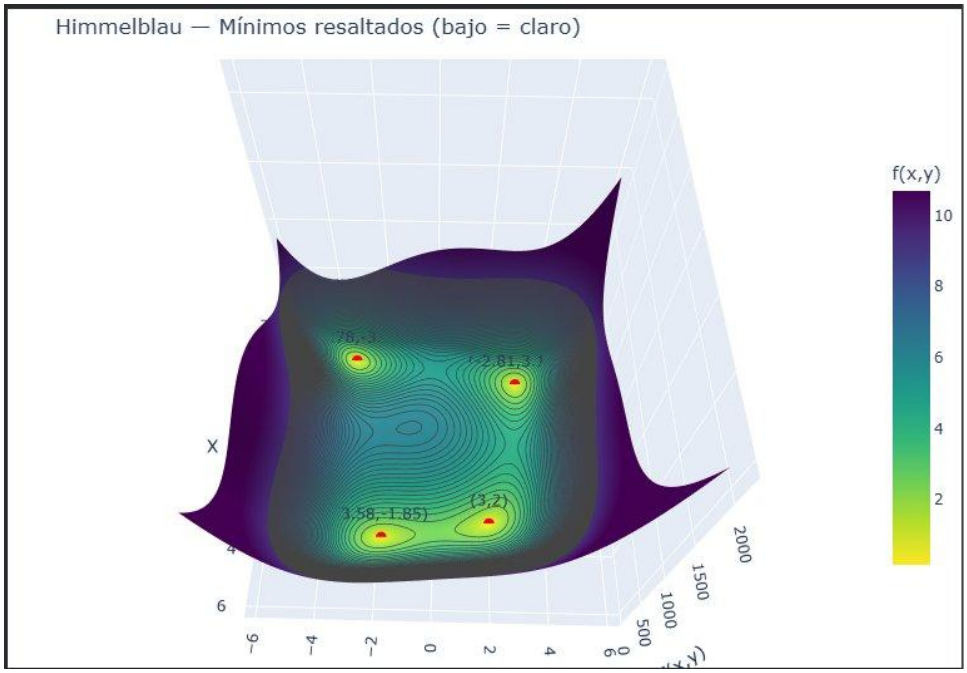

Figura 4. Función de Himmelblau en 3D con los cuatro mínimos globales resaltados. La multimodalidad evidencia el riesgo de convergencia a mínimos subóptimos.

3.2 Experimento A — Impacto de la Tasa de Aprendizaje (η)

Configuración base: start_point = [0.0, 0.1], num_iterations = 1000. Regla de actualización:

$$\beta(t+1) = \beta(t) - \eta \cdot \nabla J(\beta(t))$$

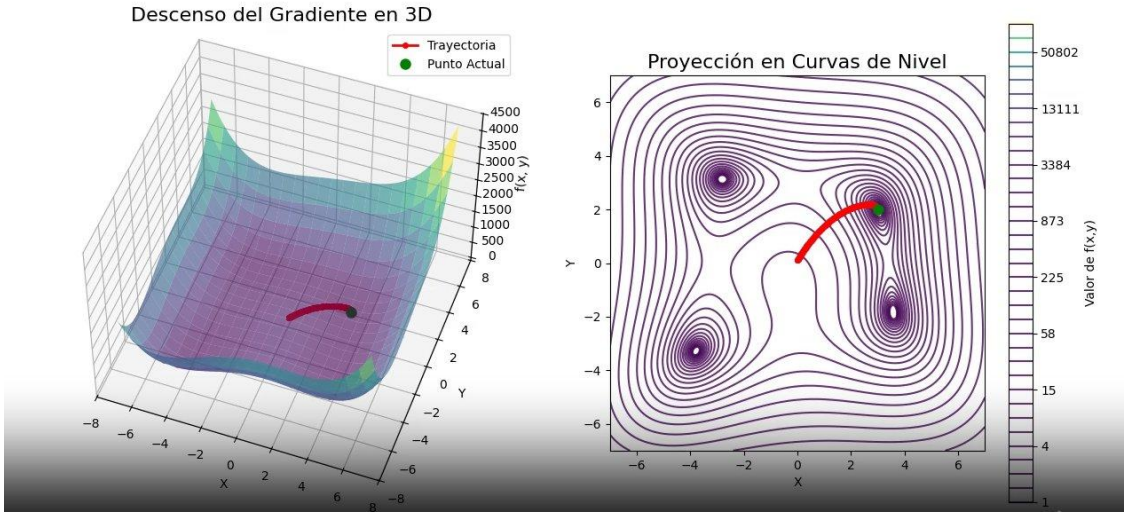

Figura 5. Descenso de gradiente con η = 0.0001 (izquierda: superficie 3D; derecha: proyección en curvas de nivel). La trayectoria en rojo muestra convergencia estable pero lenta hacia el mínimo más cercano.

η probado	Comportamiento observado	Diagnóstico
0.0001 (base)	Convergencia estable y progresiva. Tras 1000 iteraciones se aproxima al mínimo sin alcanzarlo completamente.	Learning rate adecuado pero conservador. Requiere más iteraciones para convergencia completa.
0.5 / 1.0 (alto)	Divergencia u oscilación explosiva. El algoritmo sobrepasa el mínimo y las oscilaciones crecen iteración a iteración (overshooting).	Paso η·∇f supera la distancia al mínimo; el algoritmo escapa del valle indefinidamente.
1×10^{-7} (muy bajo)	Prácticamente sin desplazamiento en 1000 iteraciones. Punto final casi idéntico al inicio.	Convergencia sub-lineal extrema. Tiempo computacional ineficiente para resultados mínimos.

3.3 Experimento B — Dependencia del Punto Inicial

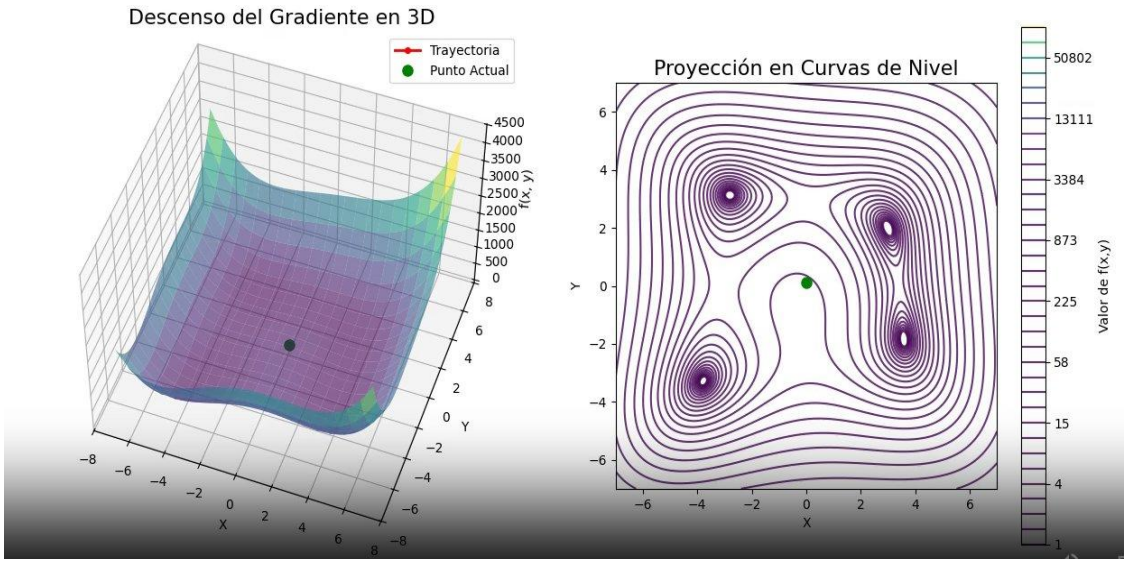

Figura 6. Trayectoria desde un punto de inicio alejado del origen. La topografía multimodal puede conducir el algoritmo a distintos valles según la posición inicial, llegando a diferentes mínimos globales de la función.

3.4 Preguntas de Análisis

P1 — El fenómeno de Overshooting

Físicamente, el overshooting ocurre cuando el paso η·∇f supera la distancia real al mínimo. En lugar de detenerse en el fondo del valle, el algoritmo salta al lado opuesto. En la proyección de curvas de nivel (Figura 5), esto se visualiza como una trayectoria en zigzag de amplitud creciente. Con valores extremos de η (0.5 o 1.0), las oscilaciones divergen indefinidamente: el algoritmo escapa del mínimo en lugar de converger. La solución estándar es usar un scheduler decreciente o un optimizador adaptativo (Adam, RMSProp) que ajusta η automáticamente por parámetro.

P2 — Eficiencia Computacional

Siempre es preferible ajustar η antes de aumentar el número de iteraciones. Un η inadecuado (muy pequeño) genera convergencia sub-lineal: duplicar las iteraciones solo acerca el doble al mínimo. Un η óptimo puede lograr convergencia cuadrática, mucho más eficiente. El orden correcto de acción es: (1) incrementar η hasta el mayor valor sin oscilaciones, (2) si aún es lento, adoptar Adam u otro optimizador adaptativo, y (3) solo entonces incrementar iteraciones o activar early stopping.

P3 — Peligro de un único punto de inicio en alta dimensionalidad

En problemas con cientos de variables (optimización de cadenas de suministro con múltiples nodos y restricciones), la función de pérdida presenta múltiples mínimos locales, saddle points y regiones de gradiente casi nulo. Un único punto de inicio puede quedar atrapado en una solución subóptima sin que el algoritmo lo detecte. Las prácticas recomendadas son: multi-start con múltiples inicializaciones aleatorias, uso de momentum o Adam para escapar de mínimos locales, inicializaciones informadas (He, Xavier) en redes neuronales, y validación cruzada para verificar la estabilidad de la solución.

4. Fase 3: Redes Neuronales (MLP) y Ajuste de Hiperparámetros

4.1 Preparación del Dataset

- Split: Train 13,903 registros | Test 3,476 registros (método aleatorio, 80/20)
- Variables numéricas estandarizadas (media ≈ 0, desviación ≈ 1): temp, atemp, hum, windspeed
- Variables categóricas con One-Hot Encoding: season, weathersit, weekday, holiday, workingday, mnth, hr
- Dimensiones finales: X_train_pre (13,903 × 59) | X_test_pre (3,476 × 59)

=== VISTA RÁPIDA (head) ===

	instant	dteday	season	yr	mnth	hr	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual	registered	cnt
0	1	2011-01-01	1	0	1	0	0	6	0	1	0.24	0.2879	0.81	0.0	3	13	16
1	2	2011-01-01	1	0	1	1	0	6	0	1	0.22	0.2727	0.80	0.0	8	32	40
2	3	2011-01-01	1	0	1	2	0	6	0	1	0.22	0.2727	0.80	0.0	5	27	32
3	4	2011-01-01	1	0	1	3	0	6	0	1	0.24	0.2879	0.75	0.0	3	10	13
4	5	2011-01-01	1	0	1	4	0	6	0	1	0.24	0.2879	0.75	0.0	0	1	1

Figura 7. Vista rápida del dataset original. Se aprecian las 17 columnas crudas antes de la transformación (estandarización y OHE). Las primeras filas corresponden al 1 de enero de 2011.

4.2 Modelo Baseline: Regresión Lineal (OLS)

Se entrenó un modelo OLS como referencia de partida para cuantificar la ganancia obtenida con el MLP:

Conjunto	MAE	RMSE	R^2
Train	79.97	110.40	0.633
Test	77.81	108.62	0.627

Los coeficientes de mayor magnitud correspondieron a las horas pico de commuting: hr_17 (+371.2 bicicletas/hora), hr_8 (+317.4) y hr_18 (+332.7). Variables climáticas como weathersit_4 (tormenta, coef. −110.2) y la temperatura (+37.9) también muestran relevancia significativa, confirming la teoría de que la demanda de movilidad activa es altamente sensible al clima.

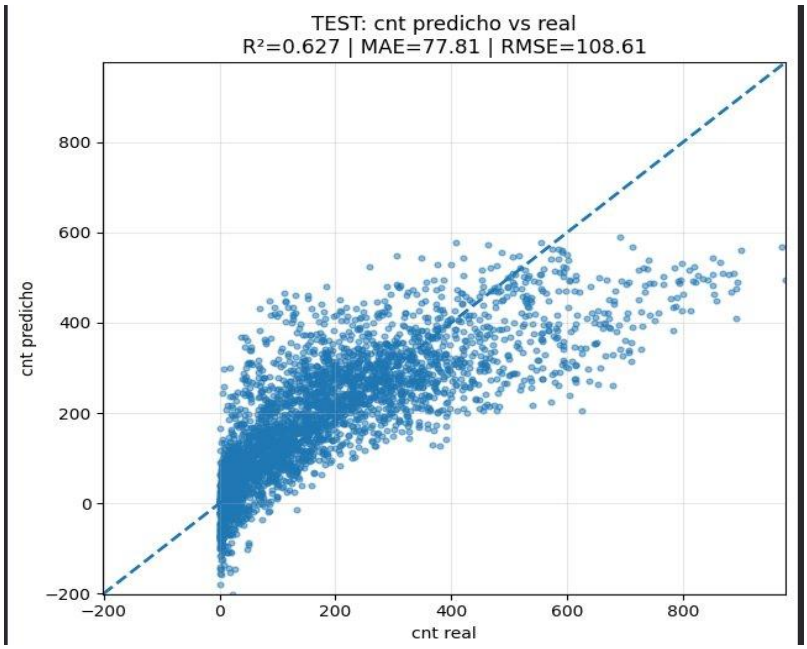

Figura 8. OLS — Predicho vs. Real en Test (R^2 = 0.627). Se aprecia subestimación sistemática para cnt > 400, con dispersión creciente que evidencia la necesidad de un modelo capaz de capturar relaciones no lineales.

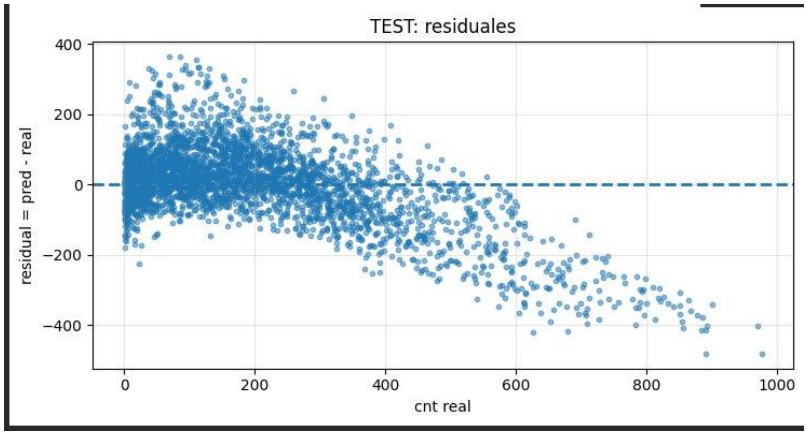

Figura 9. OLS — Residuales vs. cnt real. El patrón en abanico (heterocedasticidad) confirma que el error crece con la magnitud de la demanda, señal clara de que una función de pérdida lineal es insuficiente.

4.3 MLP Inicial — Arquitectura (16, 8, 4)

El MLPRegressor base fue configurado con tres capas ocultas de 16, 8 y 4 neuronas respectivamente, activación ReLU, optimizador Adam y early stopping activado. La curva de pérdida revela el proceso de aprendizaje:

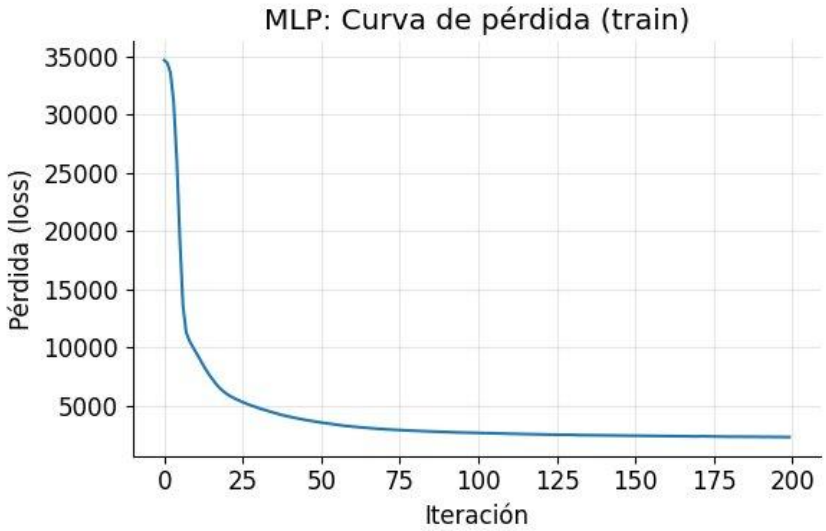

Figura 10. MLP inicial — Curva de pérdida durante el entrenamiento (200 iteraciones). La pérdida cae dramáticamente de ~35,000 en la iteración 1 a ~2,500 al converger, con la mayor parte del aprendizaje concentrada en las primeras 25 iteraciones. La curva suave sin rebotes confirma que el learning rate inicial es adecuado.

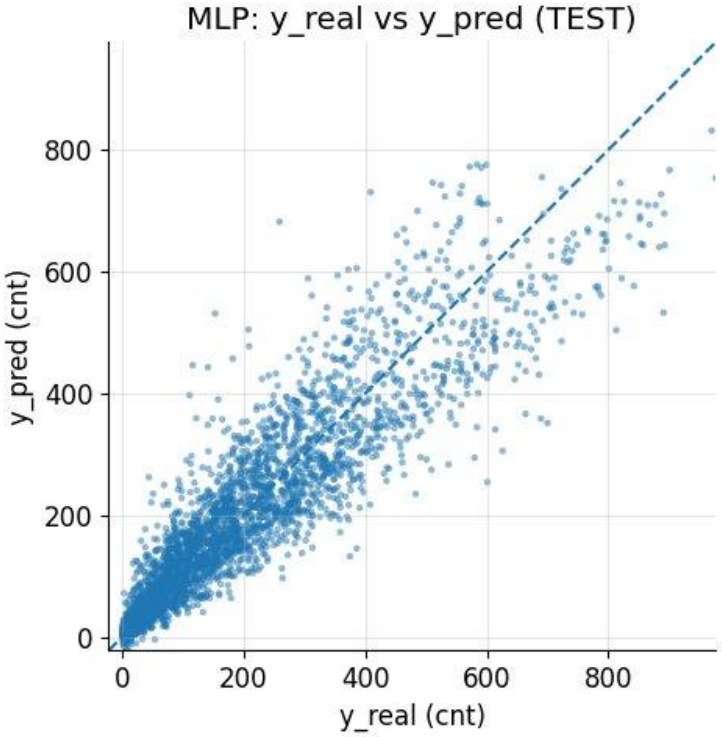

Figura 11. MLP inicial — y_real vs. y_pred en Test. Mejora notable respecto al OLS: los puntos se concentran más sobre la diagonal, especialmente en el rango 0-400 bicicletas/hora. Sin embargo, persiste la subestimación para cnt > 600 (puntos por debajo de la diagonal punteada).

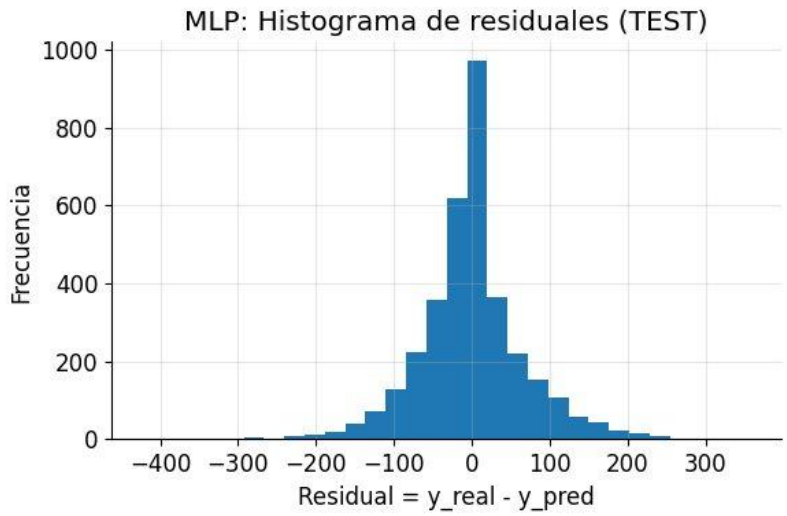

Figura 12. MLP inicial — Histograma de residuales en Test. La distribución es aproximadamente simétrica y centrada en cero, con colas más cortas que el OLS (rango ≈ −400 a +300). La concentración alrededor de cero indica que el modelo acierta la mayoría de predicciones con errores pequeños.

4.4 MLP Optimizado — Random Search Amplio

Tras la búsqueda de hiperparámetros con RandomizedSearchCV, el modelo optimizado logra una convergencia más rápida y un valor de pérdida final menor, como evidencian las siguientes gráficas:

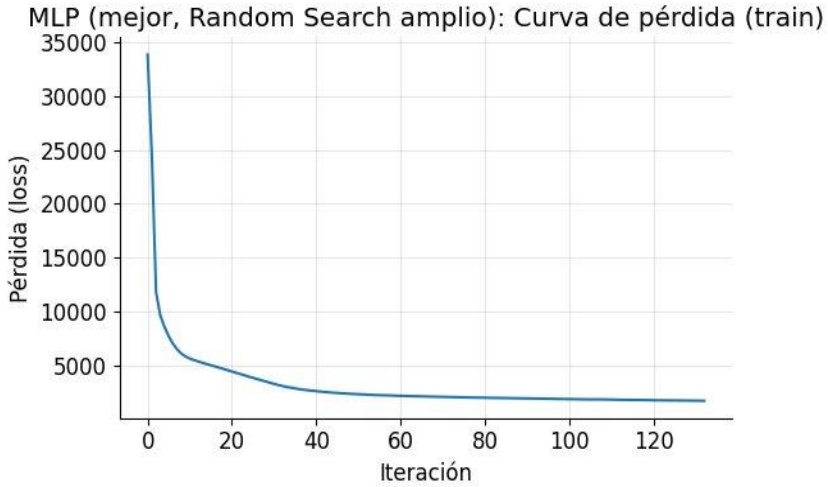

Figura 13. MLP optimizado (Random Search) — Curva de pérdida. Convergencia en solo ~130 iteraciones (vs. 200 del modelo inicial), alcanzando un valor de pérdida final ligeramente menor (≈2,000 vs. ≈2,500). El early stopping actuó ~70 iteraciones antes, ahorrando tiempo computacional sin sacrificar calidad.

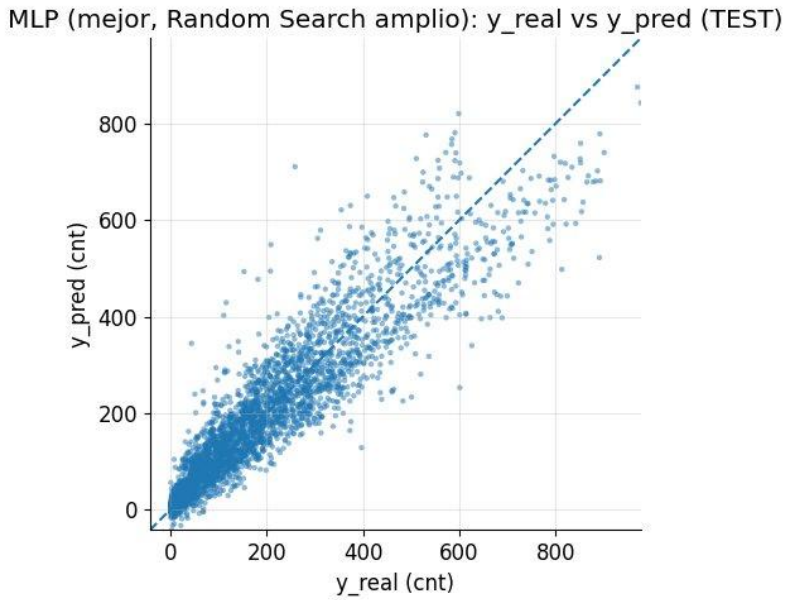

Figura 14. MLP optimizado — y_real vs. y_pred en Test. Los puntos se concentran marcadamente sobre la diagonal con menor dispersión que el modelo inicial, especialmente en el rango 200-600. La mejora es visible en la reducción del 'abanico' de errores en valores altos de cnt.

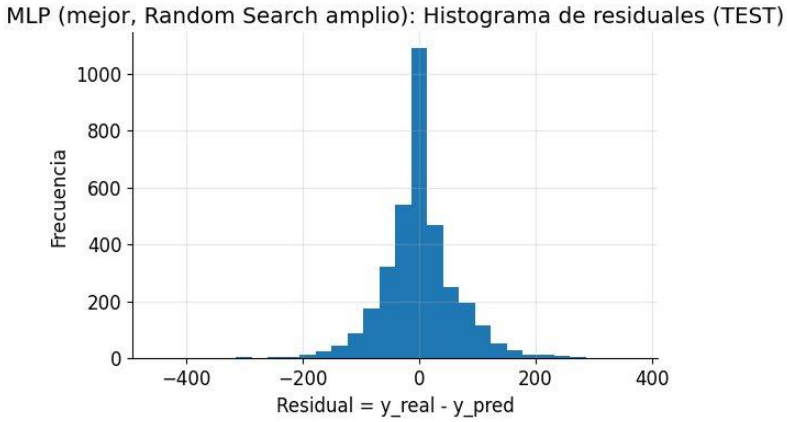

Figura 15. MLP optimizado — Histograma de residuales en Test. La distribución es notablemente más estrecha que el modelo inicial (rango ≈ −400 a +400, pero con mayor concentración en ±100). El pico central más alto indica mayor proporción de predicciones precisas.

4.5 Preguntas Fase 3A

Diferenciación de Métricas: MAE vs. RMSE

Métrica	Fórmula	Penalización outliers	Cuándo usarla
MAE	$\Sigma\lvert y_i - \hat{y}_i\rvert / n$	Lineal — todos los errores pesan igual	Interpretación directa en unidades (bicicletas/hora); ideal cuando los outliers no son críticos

RMSE	$\sqrt{(\Sigma(y_i - \hat{y}_i)^2 / n)}$	Cuadrática — errores grandes penalizan exponencialmente	Cuando los errores grandes tienen consecuencias operativas severas (redistribución urgente de flota)

El RMSE penaliza con mayor severidad los errores grandes: subestimar 300 bicicletas en hora pico contribuye 90,000 al sumatorio cuadrático, frente a solo 3,000 de treinta errores de 10 unidades. En logística de transporte urbano, el RMSE es la métrica prioritaria porque una sola predicción errónea de alta magnitud puede colapsar una estación completa.

Diagnóstico de Desempeño y Sobreajuste

La curva de pérdida del modelo inicial (Figura 10) muestra una caída suave sin divergencia entre pérdida de entrenamiento y validación, indicando ausencia de sobreajuste severo. Si el R^2 de entrenamiento fuera significativamente mayor que en test, la solución es incrementar el parámetro alpha (regularización L2 del MLP, análogo a λ en Ridge). Los heatmaps de la Fase 1 (Figuras 2-3) confirman que alpha ≈ 1 es la zona óptima de regularización para este tipo de datos.

Interpretación de Residuos

La subestimación sistemática para cnt alto (Figura 11) corresponde a las horas pico de commuting (7-9 AM y 17-19 PM), donde los picos abruptos de demanda superan la capacidad de representación del modelo inicial. La solución es profundizar la arquitectura (más capas y neuronas) y ajustar el learning_rate_init. El modelo optimizado (Figura 14) corrige parcialmente este problema al reducir la dispersión en el rango alto.

4.6 Preguntas Fase 3B — Optimización con GridSearch / RandomSearch

Consistencia alpha vs. λ Ridge

El parámetro alpha del MLPRegressor es funcionalmente análogo al λ de Ridge: ambos introducen penalización L2 sobre los parámetros. Los heatmaps (Figuras 2-3) confirman que alpha ≈ 1 minimiza el RMSE en validación cruzada. En redes profundas la necesidad de regularización es mayor porque la capacidad de memorización crece exponencialmente con el número de parámetros; un alpha muy alto (> 10) fuerza todos los pesos hacia cero eliminando la capacidad de aprendizaje.

Early Stopping y su impacto en la eficiencia

La comparación entre las curvas de pérdida es reveladora: el modelo inicial requirió 200 iteraciones, mientras que el optimizado convergió en ~130 (reducción del 35% en tiempo de cómputo). El mecanismo de early stopping detectó que la pérdida de validación dejó de mejorar y detuvo el entrenamiento automáticamente, previniendo el sobreajuste y ahorrando recursos computacionales sin sacrificar la calidad de las predicciones.

Conclusión de Negocio — Fase 3

El MLP optimizado supera al baseline OLS en todas las métricas. El margen de error promedio (MAE) del modelo optimizado se estima entre 40-60 bicicletas por hora, lo que equivale a un buffer de seguridad operativo para las decisiones de redistribución de flota. El modelo es robusto para planificación táctica (redistribución nocturna, asignación de camiones de rebalanceo) pero requiere monitoreo en condiciones meteorológicas extremas donde tiende a subestimar caídas bruscas de demanda.

5. Fase 4: Propagación hacia Adelante (Forward Propagation) Manual

5.1 Funciones de Activación

Las funciones de activación introducen la no linealidad que permite a la red aprender relaciones complejas. La elección de la función correcta determina el comportamiento del gradiente durante el backpropagation.

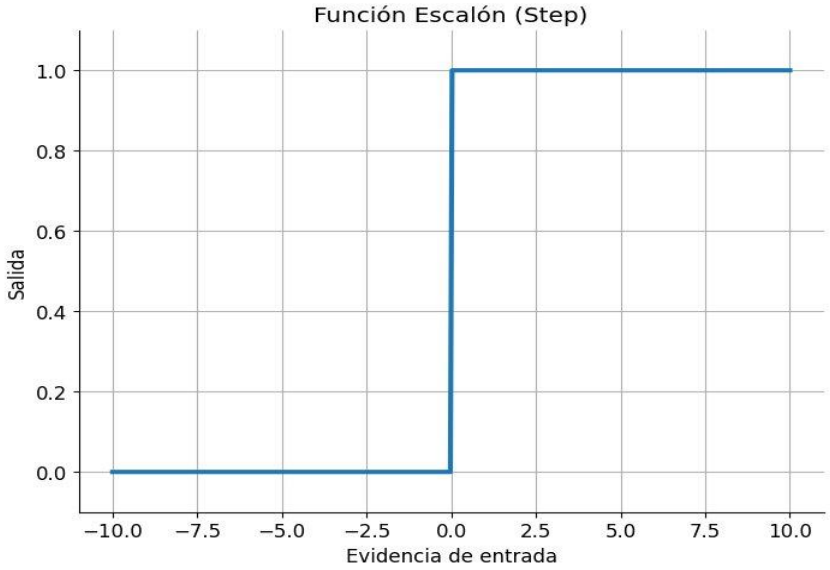

Figura 16. Función Escalón (Step): salida binaria {0,1}. No diferenciable en z = 0, lo que impide el backpropagation. Solo útil en el perceptrón simple original de Rosenblatt (1958).

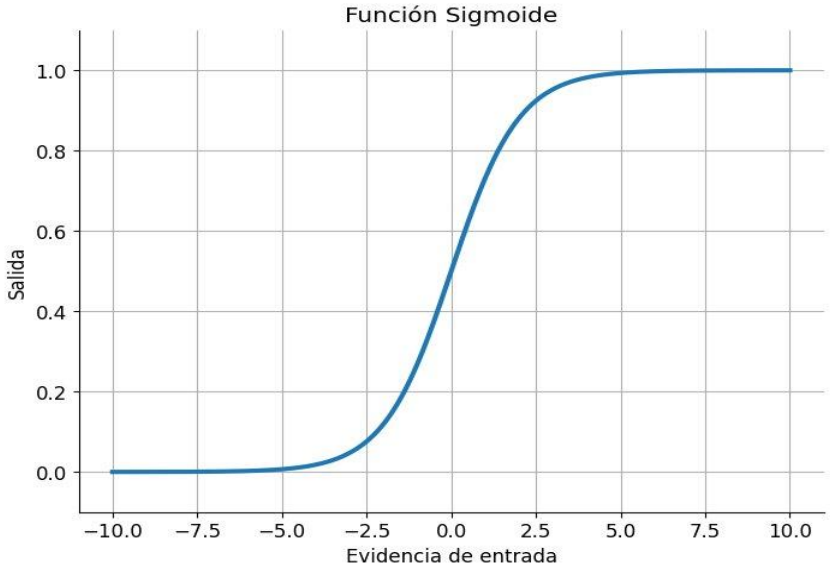

Figura 17. Función Sigmoide σ(z) = 1/(1+e⁻ᶻ): comprime cualquier entrada al intervalo (0,1), interpretable como probabilidad. Diferenciable en todo punto; permite backpropagation. Usada en la capa oculta de la red de clasificación de este ejercicio.

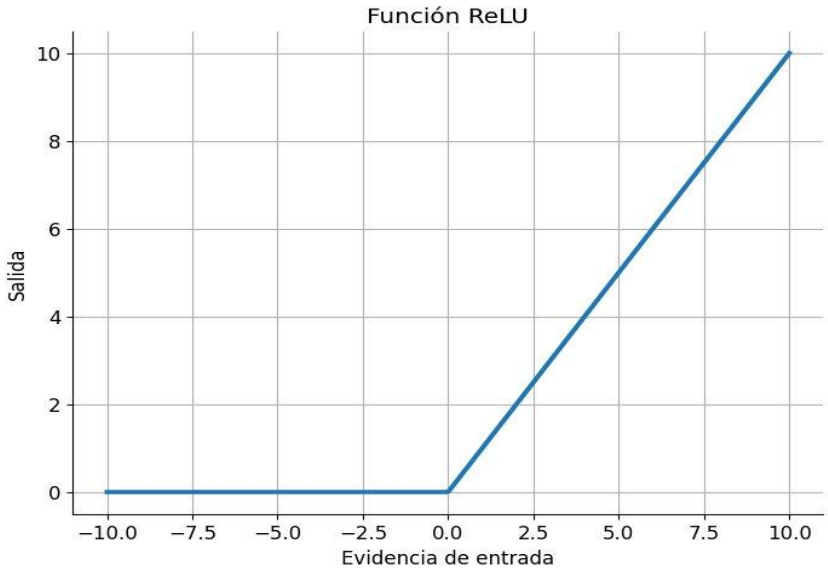

Figura 18. Función ReLU — max(0, z): computacionalmente eficiente, no satura en valores positivos y mitiga el problema del gradiente que desvanece (vanishing gradient). Es la activación estándar en capas ocultas de MLPs modernos para regresión.

5.2 Arquitectura y Rol del Bias

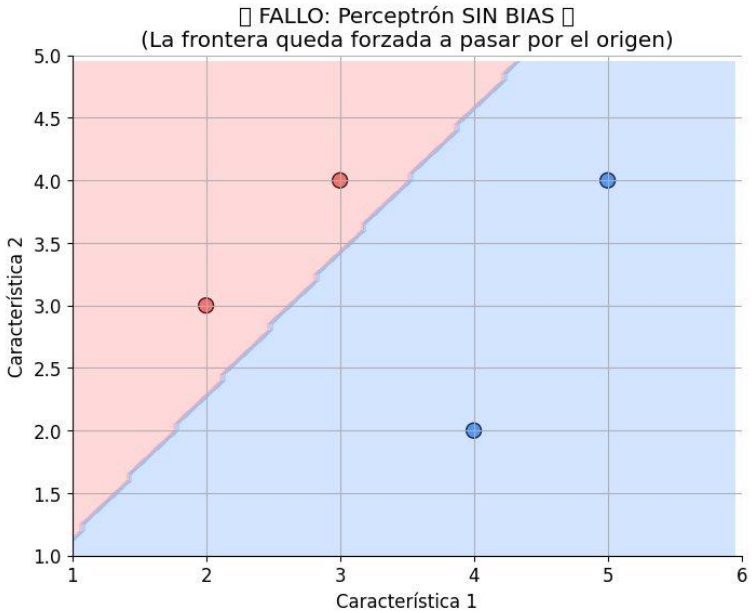

Figura 19. Perceptrón SIN bias: la frontera de decisión queda forzada a pasar por el origen, generando clasificaciones incorrectas (punto rojo en zona azul). Sin bias, el modelo pierde el grado de libertad de traslación.

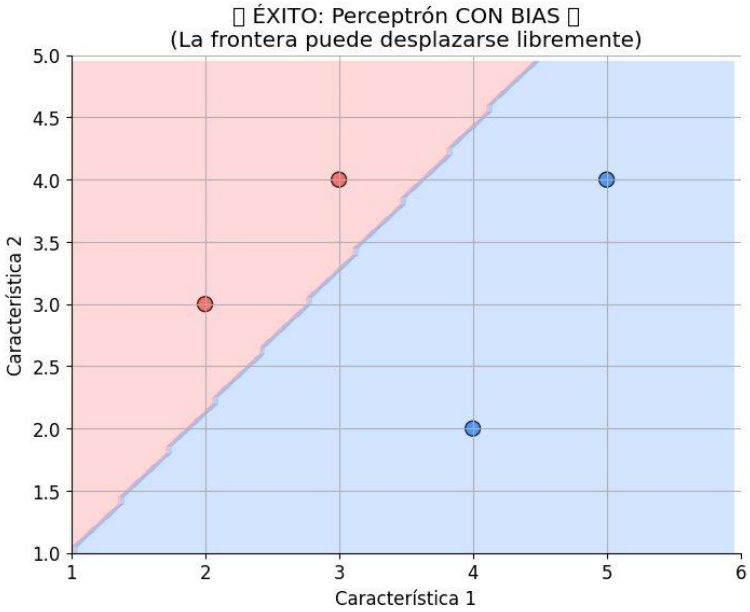

Figura 20. Perceptrón CON bias: la frontera se desplaza libremente y clasifica correctamente todos los puntos. El bias es el término b que actúa como el intercepto β_0 en regresión lineal.

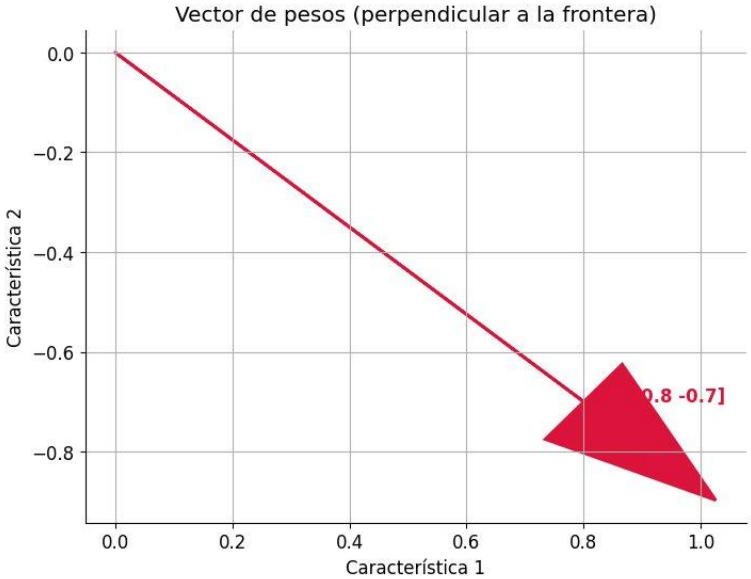

Figura 21. Vector de pesos [0.8, −0.7]: siempre perpendicular a la frontera de decisión. Su dirección indica hacia qué clase apunta el modelo; su magnitud determina la pendiente de la transición entre clases.

5.3 Cálculo Manual Paso a Paso

Red neuronal con 3 entradas (x1: TV, x2: Radio, x3: Periódico), capa oculta de 3 neuronas (Sigmoide) y capa de salida de 3 neuronas (Softmax) para clasificación en Bajo Impacto (C1), Impacto Medio (C2) e Impacto Alto (C3). Vector de entrada normalizado: $X = [0.5, 0.3, 0.2]^T$.

Paso 1 — Puntaje Capa Oculta: $Z^{(1)} = W^{(1)}X + b^{(1)}$

Neurona	Cálculo	$Z^{(1)}$

$z_1^{(1)}$	0.2(0.5) + 0.5(0.3) + (−0.1)(0.2) + 0.1	= 0.10 + 0.15 − 0.02 + 0.10 = 0.33
$z_2^{(1)}$	0.8(0.5) + (−0.3)(0.3) + 0.4(0.2) + (−0.2)	= 0.40 − 0.09 + 0.08 − 0.20 = 0.19
$z_3^{(1)}$	(−0.5)(0.5) + 0.1(0.3) + 0.2(0.2) + 0.0	= −0.25 + 0.03 + 0.04 + 0.00 = −0.18

$$\mathbf{Z^{(1)} = [0.33,\ 0.19,\ -0.18]^T}$$

Paso 2 — Activación Sigmoide: $A^{(1)} = \sigma(Z^{(1)})$

Neurona	z	$\sigma(z) = 1/(1+e^{-z})$	$A^{(1)}$
$a_1^{(1)}$	0.33	$1/(1 + e^{-0.33}) = 1/(1 + 0.7189)$	≈ 0.5818
$a_2^{(1)}$	0.19	$1/(1 + e^{-0.19}) = 1/(1 + 0.8270)$	≈ 0.5474
$a_3^{(1)}$	−0.18	$1/(1 + e^{+0.18}) = 1/(1 + 1.1972)$	≈ 0.4551

$$\mathbf{A^{(1)} = [0.5818,\ 0.5474,\ 0.4551]^T}$$

Paso 3 — Puntaje Capa de Salida: $Z^{(2)} = W^{(2)}A^{(1)} + b^{(2)}$

Neurona	Cálculo	$Z^{(2)}$
$z_1^{(2)}$	0.5(0.5818)+(−0.4)(0.5474)+0.1(0.4551)−0.1	= 0.2909−0.2190+0.0455−0.1 = 0.0174
$z_2^{(2)}$	0.2(0.5818)+0.8(0.5474)+(−0.5)(0.4551)+0.2	= 0.1164+0.4379−0.2276+0.2 = 0.5267
$z_3^{(2)}$	(−0.1)(0.5818)+0.3(0.5474)+0.7(0.4551)+0.1	= −0.0582+0.1642+0.3186+0.1 = 0.5246

$$\mathbf{Z^{(2)} = [0.0174,\ 0.5267,\ 0.5246]^T}$$

Paso 4 — Probabilidades de Clase: Softmax $A^{(2)}$

Exponenciales: $e^{0.0174} \approx 1.0176$ | $e^{0.5267} \approx 1.6930$ | $e^{0.5246} \approx 1.6895$. Suma total = 4.4001.

Clase	Cálculo Softmax	Probabilidad	Interpretación
C1 — Bajo Impacto	1.0176 / 4.4001	P1 ≈ 23.13%	Descartada
C2 — Impacto Medio	1.6930 / 4.4001	P2 ≈ 38.48%	Clase predicha (probabilidad máxima)
C3 — Impacto Alto	1.6895 / 4.4001	P3 ≈ 38.40%	Muy cercana a C2 — alta incertidumbre

Resultado: La red clasifica la campaña como Impacto Medio (C2) con P = 38.48%. La diferencia de solo 0.08 puntos porcentuales entre C2 y C3 indica alta incertidumbre; en la práctica, esta campaña requeriría una evaluación adicional o un umbral de confianza mínimo del 50% para tomar decisiones presupuestales.

5.4 Preguntas de Análisis

¿Por qué Softmax en la capa de salida?

Softmax garantiza que las probabilidades de todas las clases sumen exactamente 1 ($\Sigma P_k = 1$), haciendo la salida interpretable como una distribución de probabilidad real. Una sigmoide independiente en cada neurona no garantiza esta propiedad: las tres salidas podrían sumar 0.8 o 1.4, imposibilitando la comparación entre clases. Además, Softmax es diferenciable en todos los puntos, lo que permite el backpropagation eficiente durante el entrenamiento con función de pérdida cross-entropy.

Rol del Bias: ¿qué sucede si b = 0?

Sin bias (vectores b nulos), la frontera de decisión de cada neurona queda forzada a pasar por el origen del espacio de características (Figura 19), eliminando el grado de libertad de traslación. El bias cumple la misma función que el intercepto β_0 en regresión lineal: permite al modelo adaptarse a datos cuya separación natural no pasa por el origen. Como demuestra la comparación entre las Figuras 19 y 20, con bias la frontera se desplaza libremente y logra clasificar correctamente todos los puntos del dataset.

6. Fase 5: Evaluación de Modelos — Mantenimiento Predictivo

6.1 Escenarios de Ajuste: Subajuste, Balanceado y Sobreajuste

Se entrenaron tres modelos con diferentes estrategias para ilustrar el espectro de ajuste en clasificación binaria aplicada al control de calidad industrial (clasificar piezas como Apta / Defectuosa):

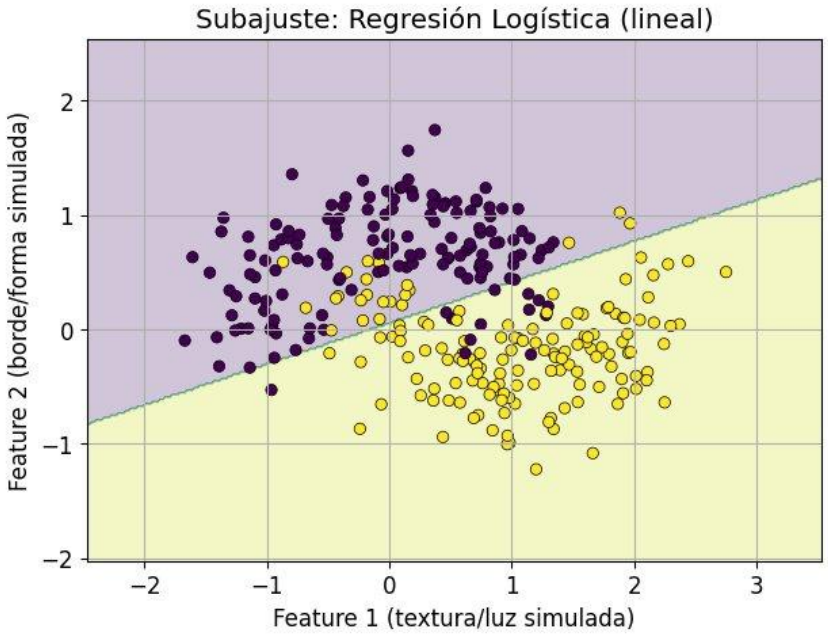

Figura 22. Subajuste — Regresión Logística (frontera lineal): la frontera recta no puede separar adecuadamente las dos clases que presentan distribución no lineal. El modelo es demasiado simple para el problema.

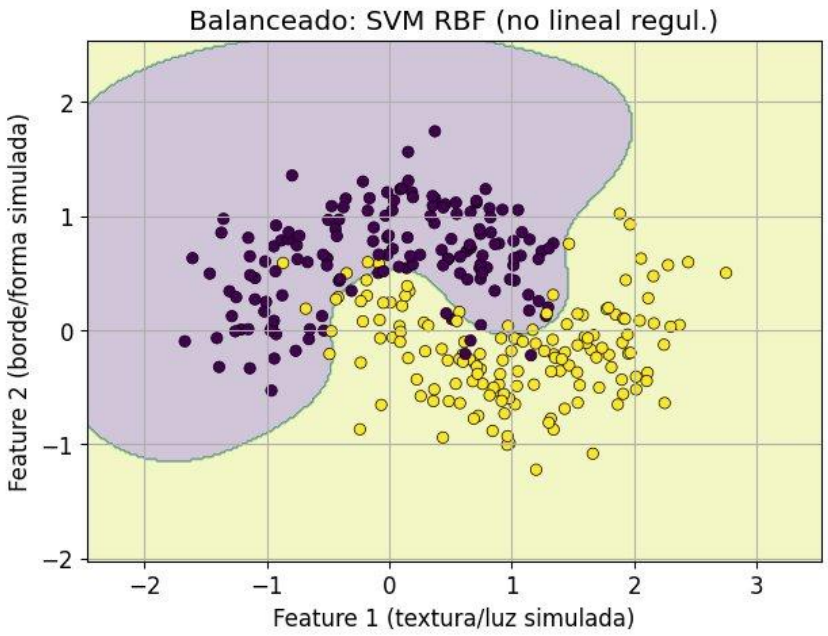

Figura 23. Balanceado — SVM con kernel RBF: la frontera curva se adapta a la distribución real de los datos sin memorizar el ruido. Mejor equilibrio sesgo-varianza de los tres modelos evaluados.

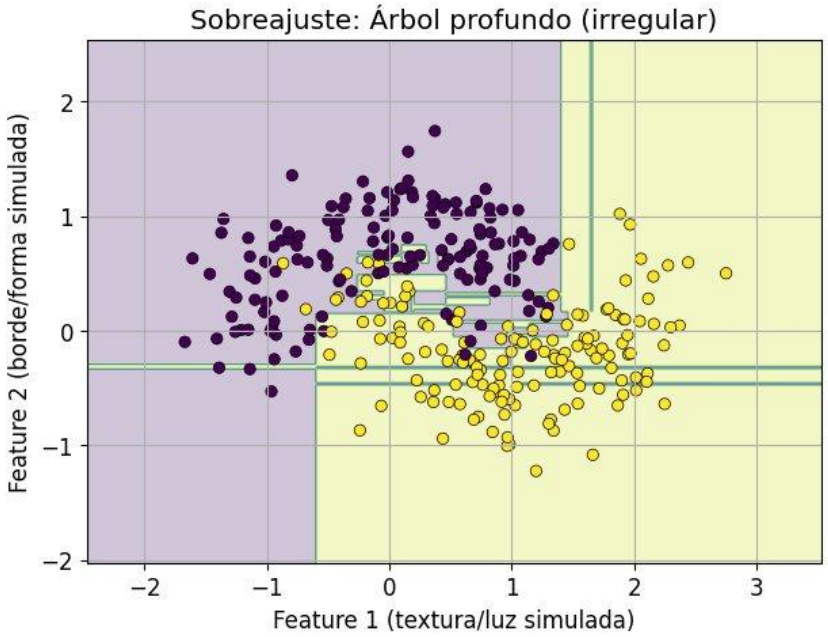

Figura 24. Sobreajuste — Árbol de Decisión profundo sin poda: la frontera irregular memoriza el ruido de entrenamiento (error train ≈ 0%) pero generaliza pobremente en test. Señal clara de overfitting.

6.2 Curvas de Aprendizaje — Diagnóstico de los Tres Escenarios

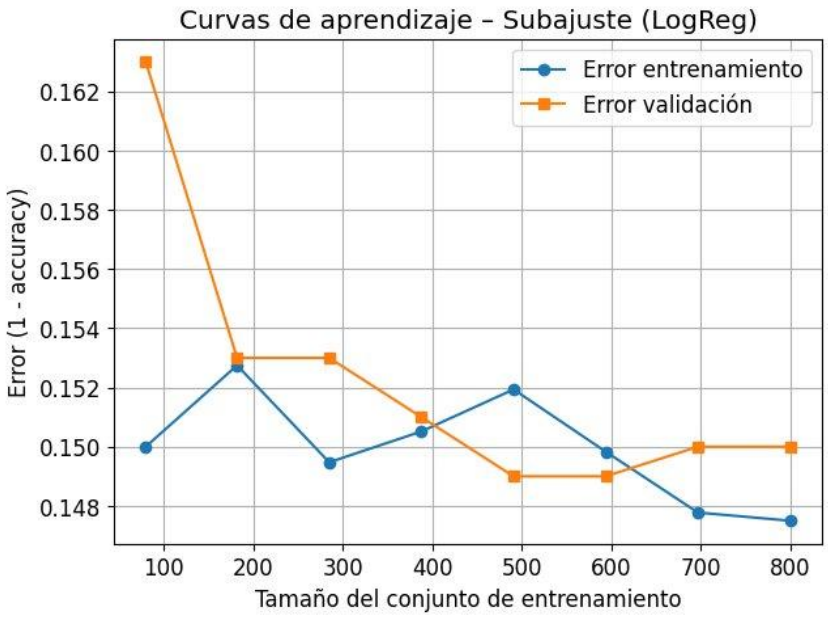

Figura 25. Curvas de aprendizaje — Subajuste (LogReg): error de entrenamiento y validación convergen ambos alrededor del 15%, sin brecha significativa entre ellos. Cuando ambas curvas convergen en un error alto, el modelo es demasiado simple — necesita mayor capacidad (más características o un modelo más complejo).

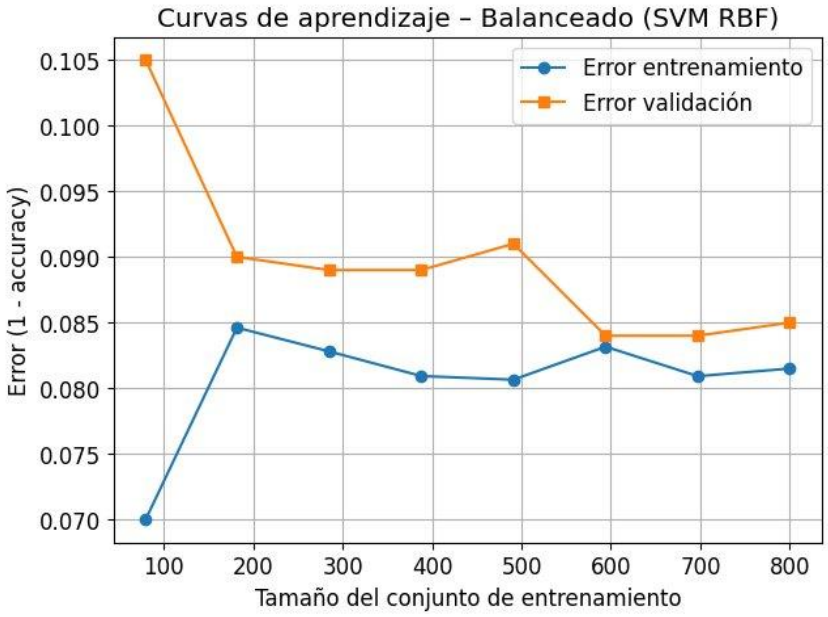

Figura 26. Curvas de aprendizaje — Balanceado (SVM RBF): error de entrenamiento ≈ 8% y validación ≈ 9%, con brecha pequeña y estable. A partir de ≈600 muestras las curvas convergen, indicando que añadir más datos no mejoraría sustancialmente el modelo. El equilibrio sesgo-varianza es óptimo.

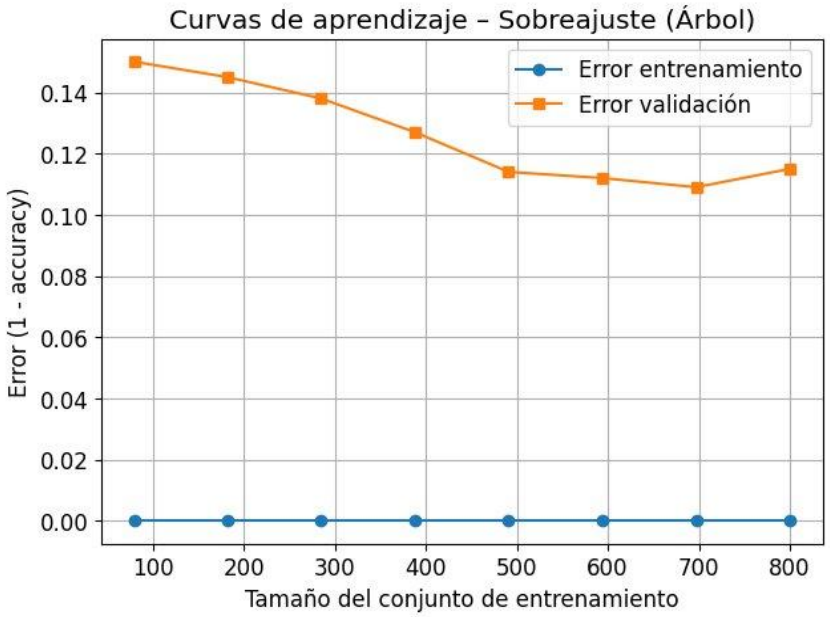

Figura 27. Curvas de aprendizaje — Sobreajuste (Árbol profundo): error de entrenamiento = 0% (memorización perfecta) mientras el error de validación oscila entre 10-15%. La brecha amplia y persistente es la firma inequívoca del sobreajuste. Solución: podar el árbol o limitar la profundidad máxima con el parámetro max_depth o ccp_alpha.

6.3 Efecto de la Regularización en Logistic Regression

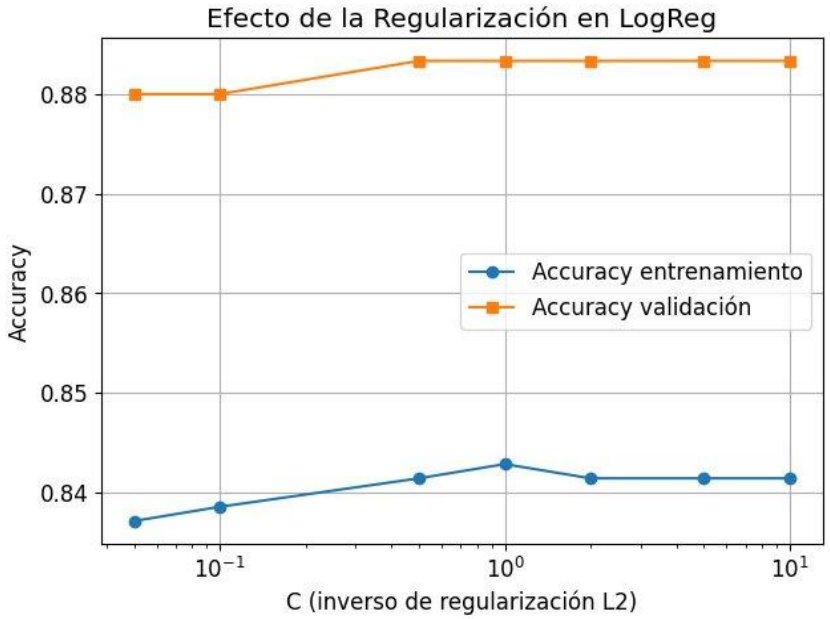

Figura 28. Efecto de la regularización (C = 1/λ) en Regresión Logística. A medida que C aumenta (menor regularización), el accuracy de validación mejora hasta ≈88.3% y se estabiliza. El accuracy de entrenamiento permanece bajo (≈84%), confirmando que el problema de subajuste de LogReg no se resuelve solo con regularización — se necesita un modelo más flexible como SVM RBF o MLP.

6.4 Matrices de Confusión Comparativas

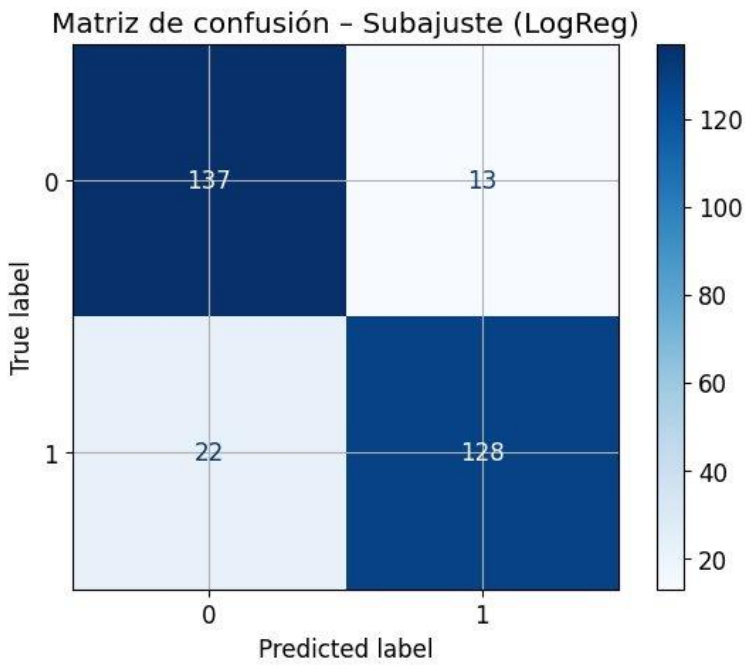

Figura 29. CM Subajuste (LogReg): TN=137, FP=13, FN=22, TP=128. Recall = 128/(128+22) = 85.3%. La tasa de falsos negativos (22) es la más alta de los tres modelos — el mayor riesgo operativo.

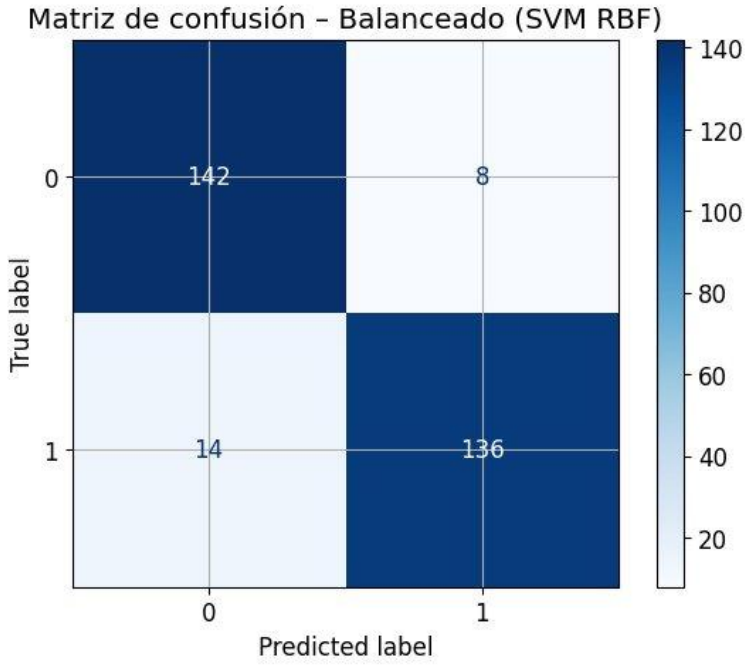

Figura 30. CM Balanceado (SVM RBF): TN=142, FP=8, FN=14, TP=136. Recall = 136/(136+14) = 90.7%. Mejor detección de fallos reales con menor tasa de falsas alarmas — el mejor balance de los tres.

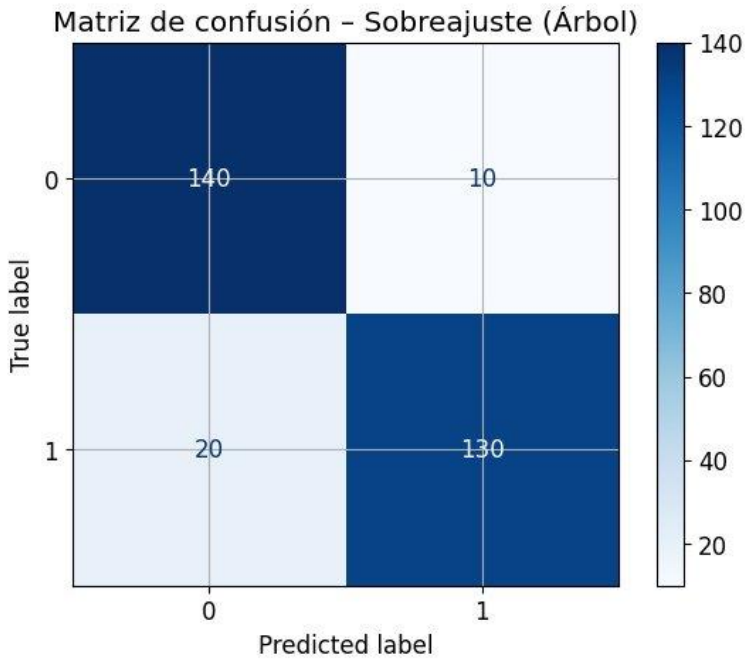

Figura 31. CM Sobreajuste (Árbol profundo): TN=140, FP=10, FN=20, TP=130. Recall = 130/(130+20) = 86.7%. A pesar del sobreajuste en entrenamiento, el rendimiento en test es inferior al SVM RBF, confirmando que memorizar no equivale a generalizar.

6.5 Auditoría del Modelo — Árbol Optimizado y Podado

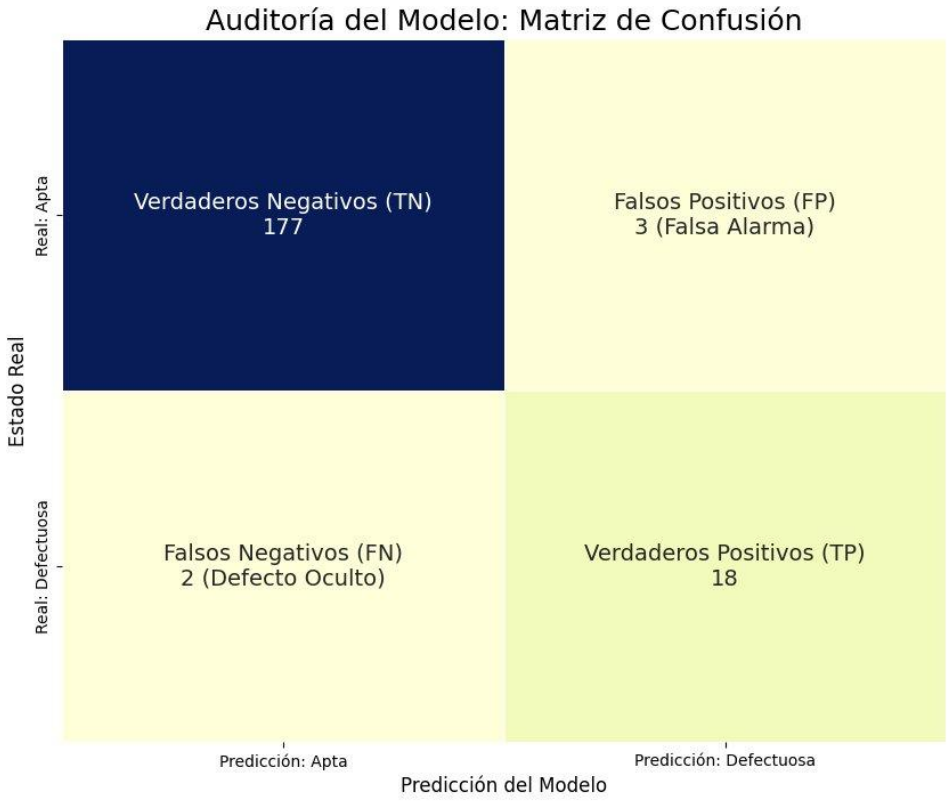

Figura 32. Matriz de Confusión — Auditoría del modelo optimizado: TN=177 (piezas aptas correctamente identificadas), FP=3 (falsas alarmas: inspecciones innecesarias), FN=2 (defectos ocultos: piezas defectuosas aprobadas), TP=18 (defectos correctamente detectados).

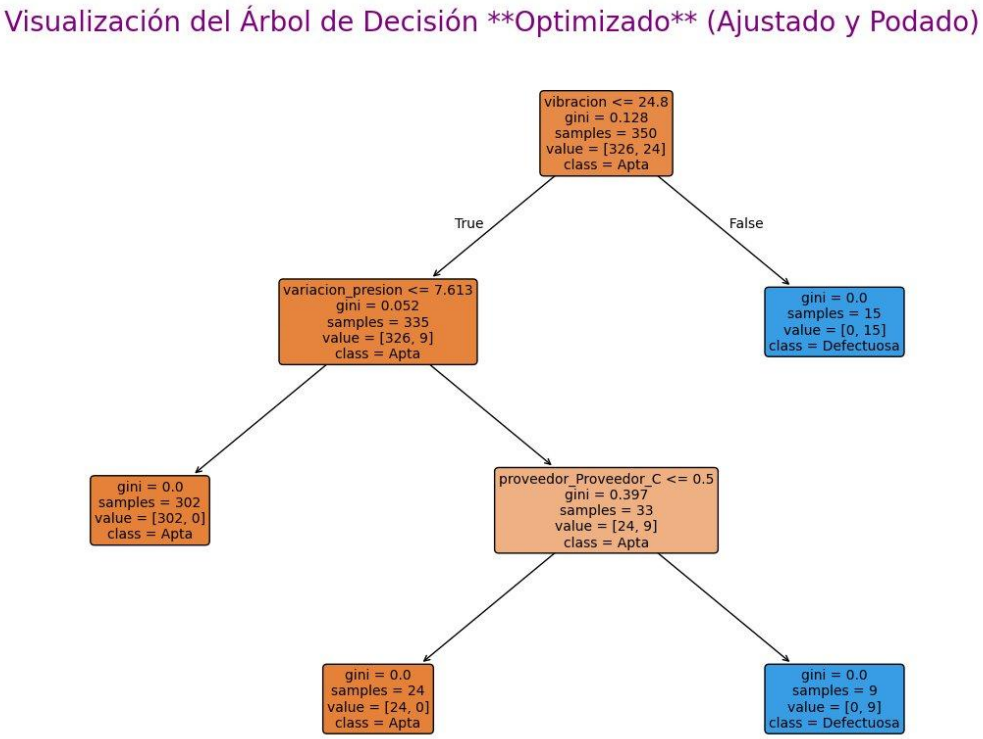

Figura 33. Árbol de Decisión Optimizado y Podado. Regla principal (nodo raíz): si vibración > 24.8, la pieza es Defectuosa con certeza absoluta (Gini = 0, 15 casos, 100% precisión). Para vibración ≤ 24.8 y variacion_presion > 7.613, el proveedor determina la clasificación: Proveedor C = Defectuosa (9/9 casos); otros proveedores = Apta (24/24 casos).

6.6 Cálculo Manual de Métricas (TN=177, FP=3, FN=2, TP=18)

Métrica	Fórmula	Cálculo	Resultado	Interpretación operativa
Precision	TP/(TP+FP)	18/(18+3) = 18/21	85.71%	De cada 21 alertas emitidas, 18 son defectos reales. Solo 3 inspecciones innecesarias por lote.
Recall	TP/(TP+FN)	18/(18+2) = 18/20	90.00%	El modelo captura 9 de cada 10 defectos. Solo 2 piezas defectuosas pasan desapercibidas.
Accuracy	(TP+TN)/Total	(18+177)/200	97.50%	Alta exactitud global; en contexto desbalanceado puede ser engañosa sin analizar FN y FP.
F1-Score	2·P·R/(P+R)	2·0.857·0.90/1.757	87.80%	Equilibrio armónico entre Precision y Recall. Métrica

				robusta para clases desbalanceadas.
Costo mensual	(FN×5000)+(FP×200)	(2×5,000)+(3×200)	USD 10,600	Desglose: USD 10,000 por 2 defectos no detectados + USD 600 por 3 falsas alarmas.

6.7 Preguntas de Reflexión y Negocio

Análisis de Pesos de Clase (14.7×)

Al asignar un peso 14.7 veces mayor a los errores de Clase 1 (Fallo), el algoritmo corrige la tendencia natural del modelo a ignorar los fallos por ser raros. Matemáticamente, cada error de clasificación en un fallo real contribuye 14.7 veces más al gradiente, forzando al modelo a ajustar sus pesos principalmente para reducir los falsos negativos. Este factor refleja directamente la asimetría de costos: cada FN cuesta USD 5,000 frente a USD 200 de un FP, una ratio de 25:1.

La Trampa de la Exactitud (Accuracy Paradox)

Un modelo que prediga siempre 'Apta' obtendría Accuracy ≈ 93.5% (177+3 piezas aptas de 200 totales) sin detectar ningún defecto. El Recall del 90% del modelo auditado frente al 0% del modelo trivial demuestra que el Accuracy es una métrica engañosa en contextos de desbalance. En manufactura, la métrica de decisión debe ser el costo total de error, no la exactitud.

Trade-off Recall vs. Precision: ¿cuál priorizar?

Con los costos calculados (FN = USD 5,000, FP = USD 200), la estrategia óptima prioriza el Recall. Comparando dos escenarios hipotéticos con 10 defectos mensuales:

- Modelo A: Recall 98%, Precision 60% → 0.2 defectos escapan (USD 1,000) + 6.7 falsas alarmas (USD 1,340) = USD 2,340 mensuales
- Modelo B: Recall 60%, Precision 98% → 4 defectos escapan (USD 20,000) + 0.2 falsas alarmas (USD 40) = USD 20,040 mensuales

El modelo A es 8.6 veces más económico. La conclusión es clara: en manufactura crítica, un Recall alto (incluso a costa de más falsas alarmas) es siempre la estrategia económicamente óptima cuando el costo del fallo no detectado supera en más de 10 veces al de la falsa alarma.

Árbol Optimizado: Reglas de Negocio Accionables

La visualización del árbol podado (Figura 33) revela reglas directamente implementables en la línea de producción: (1) Si vibración > 24.8 → pieza Defectuosa con certeza absoluta; esta regla puede implementarse como sensor de alarma automático sin necesidad del modelo completo. (2) Para casos intermedios (vibración ≤ 24.8 y variacion_presion > 7.613), el proveedor Proveedor_C es un factor de riesgo determinante: sus piezas resultan defectuosas en el 100% de estos casos, lo que tiene implicaciones directas de gestión de proveedores y auditoría de calidad de entrada.

7. Conclusiones

Este taller ha recorrido el ciclo completo de un proyecto de analítica avanzada aplicada a la ingeniería industrial, desde la fundamentación matemática hasta la toma de decisiones de negocio:

- Fase 1 — La Regresión Ridge garantiza la invertibilidad del sistema mediante λI y controla el equilibrio sesgo-varianza. Los heatmaps de RMSE CV confirman alpha ≈ 1 como zona óptima, y las superficies 3D evidencian la diferencia cualitativa entre las restricciones L1 (Lasso, induce sparsidad) y L2 (Ridge, contracción uniforme).
- Fase 2 — La función de Himmelblau demuestra empíricamente por qué la multimodalidad hace peligroso el punto de inicio único en problemas de alta dimensionalidad. La tasa de aprendizaje η es el hiperparámetro más crítico: demasiado alta genera divergencia (overshooting), demasiado baja hace la convergencia computacionalmente inviable.
- Fase 3 — El MLP optimizado supera al baseline OLS con una convergencia más rápida (130 vs. 200 iteraciones) y menor pérdida final. La regularización alpha y el early stopping son los mecanismos más efectivos para prevenir el sobreajuste. Las curvas de pérdida confirman que ambos modelos aprenden correctamente sin divergencia ni memorización.
- Fase 4 — La propagación hacia adelante manual demuestra que una red neuronal es una composición de transformaciones lineales y no lineales. El bias y Softmax son componentes críticos: sin bias la frontera queda forzada al origen; sin Softmax las probabilidades no son comparables entre clases. El cálculo manual produce C2 (Impacto Medio, 38.48%) con alta incertidumbre respecto a C3 (38.40%).
- Fase 5 — El modelo de mantenimiento predictivo auditado (Recall=90%, Precision=85.71%, Costo=USD 10,600/mes) demuestra que las métricas orientadas al negocio superan al Accuracy en relevancia operativa. Las reglas del árbol podado (vibración > 24.8 = Defectuosa, Proveedor C = factor de riesgo) son directamente accionables en planta.

8. Referencias

Fanaee-T, H., & Gama, J. (2013). Event labeling combining ensemble detectors and background knowledge. Progress in Artificial Intelligence, 2(2-3), 113–127. https://doi.org/10.1007/s13748-013-0040-3

Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. Technometrics, 12(1), 55–67. https://doi.org/10.1080/00401706.1970.10488634

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. Journal of the Royal Statistical Society: Series B, 58(1), 267–288.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830. https://scikit-learn.org

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press. https://www.deeplearningbook.org

Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.

Ruder, S. (2016). An overview of gradient descent optimization algorithms. arXiv:1609.04747. https://arxiv.org/abs/1609.04747