Análisis Estadístico y Modelado Predictivo con Regresión Lineal: Estudio del Dataset Advertising

Santiago Alfonso Aviles Buitrago
Haider Fabian Rodríguez Orjuela
Brayan Mauricio Toro
Asignatura: Sistemas de Análisis y Procesamiento de Proyectos (SAPP) | IIND 2026
Repositorio: github.com/faorjuelal/SAPP---IIND---2026
Fecha: Marzo 2026

Abstract

Este informe presenta el análisis estadístico completo del Dataset Advertising, compuesto por 200 observaciones de ventas en diferentes mercados y presupuestos publicitarios en TV, Radio y Periódico. Se desarrollan modelos de Regresión Lineal Simple y Múltiple utilizando el método de mínimos Cuadrados Ordinarios (OLS), junto con análisis exploratorio de datos (EDA), métricas de correlación de Pearson y Spearman, y evaluación de desempeño mediante R2, MSE y RMSE. Los resultados muestran que el modelo múltiple (TV + Radio + periódico) alcanza un coeficiente de determinación de R2=0.8972, superando significativamente al modelo simple (R2=0.6109), evidenciando la importancia de considerar múltiples predictores en el modelado predictivo. El Radio emerge como el canal publicitario de mayor impacto marginal por dólar invertido (beta_2=0.1885), mientras el periódico muestra un coeficiente negativo e insignificante.

Palabras clave— *Regresión lineal, OLS, EDA, Pearson, Spearman, R^2, RMSE, Dataset Advertising, predicción de ventas.*

I. INTRODUCCIÓN

El modelado estadístico mediante regresión lineal es una de las herramientas fundamentales en ciencia de datos, ingeniería industrial y áreas cuantitativas aplicadas. Su capacidad para cuantificar relaciones entre variables y generar predicciones interpretables lo hace especialmente valioso en contextos de toma de decisiones.

El presente trabajo analiza el Dataset Advertising, ampliamente utilizado en la literatura estadística [1], para explorar cómo la inversión en diferentes medios publicitarios (TV, Radio y Periódico) impacta en el volumen de ventas de un producto en 200 mercados. El análisis sigue una metodología estructurada que comprende la preparación de los datos, el análisis exploratorio, la construcción de modelos y la evaluación de su capacidad predictiva.

El objetivo principal es comparar el poder explicativo de la regresión simple (un solo predictor) frente a la regresión múltiple (múltiples predictores), cuantificando la mejora obtenida al incorporar variables adicionales al modelo.

II. DESCRIPCIÓN DEL DATASET Y PREPARACIÓN

El Dataset Advertising proviene del libro 'An Introduction to Statistical Learning' (ISLR) [1] y contiene 200 registros de mercados independientes. Para cada mercado se registran cuatro variables:

Variable	Descripción	Tipo / Unidades
TV	Presupuesto publicitario en televisión	Continua / Miles de dólares (float64)
radio	Presupuesto publicitario en radio	Continua / Miles de dólares (float64)
newspaper	Presupuesto publicitario en periódico	Continua / Miles de dólares (float64)
sales	Volumen de ventas del producto	Continua / Miles de unidades (float64)

Tabla I. Variables del Dataset Advertising

Antes de iniciar el análisis, se verificó la integridad de los datos: el Dataset no presenta valores faltantes (NaN), todas las variables son de tipo float64, y el índice fue correctamente establecido mediante el parámetro index_col=0 en la lectura del archivo CSV. La muestra de 200 observaciones es suficiente para garantizar la validez estadística del modelo OLS.

III. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

A. Estadística Descriptiva

La Tabla II presenta las principales métricas de tendencia central y dispersión para las cuatro variables del dataset. Destaca que la variable TV presenta la mayor variabilidad (σ=87.20), con valores que oscilan entre ~2.33 y ~292.52 miles de dólares, reflejando una distribución aproximadamente uniforme (asimetría=0.09). Las ventas tienen una media de 14.22 con desviación estándar de 4.98, lo que indica una variabilidad moderada entre mercados.

Variable	Media	Mediana	Desv. Est.	Mín.	Máx.	Asimetría
TV	143.82	146.92	87.20	2.33	292.52	0.09
Radio	25.02	26.87	14.53	0.25	49.13	-0.13
Newspaper	59.50	60.04	34.94	1.53	113.97	-0.07
Sales	14.22	14.53	4.98	0.79	24.03	-0.19

Tabla II. Estadística Descriptiva del Dataset Advertising

B. Distribución de Variables: Histogramas y Boxplots

La Fig. 1 presenta los histogramas con curvas de densidad (KDE) y los diagramas de caja para las variables TV y Ventas.

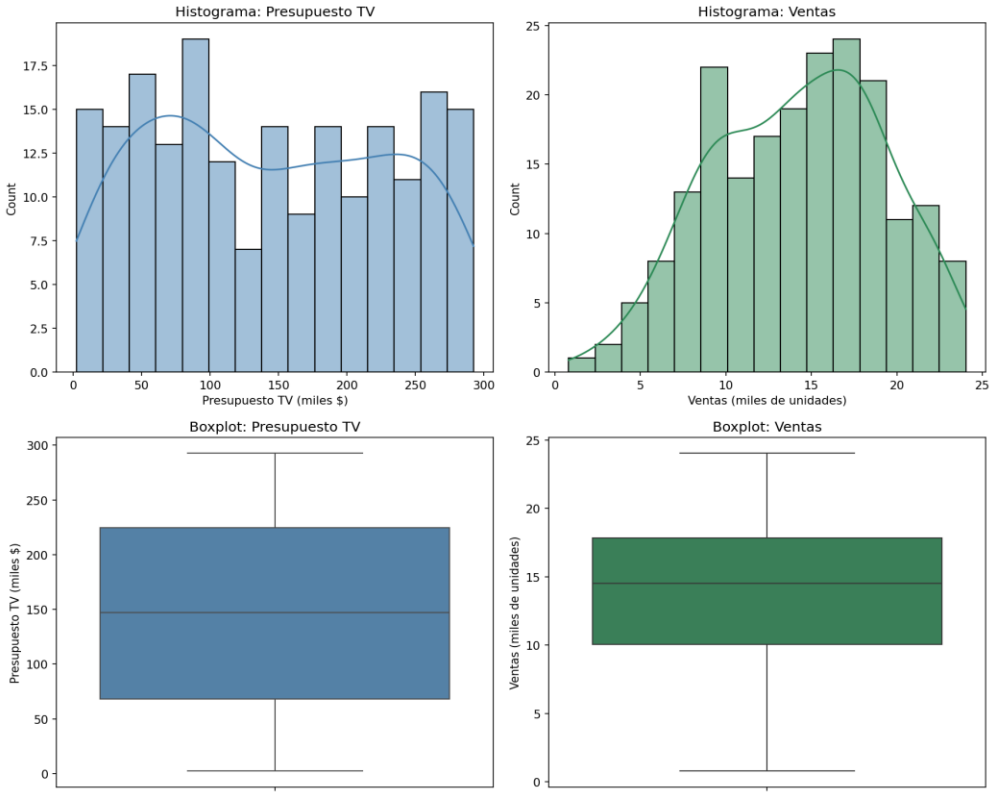

Fig. 1. Histogramas y boxplots de las variables TV (azul) y Ventas (verde).

Del análisis visual se desprenden las siguientes observaciones:

TV: La distribución es esencialmente uniforme (asimetría=0.09), sin presencia de valores atípicos en el boxplot. Esto indica que el Dataset fue diseñado con una cobertura equilibrada de los distintos niveles de inversión publicitaria, lo cual es favorable para la estimación de la pendiente del modelo de regresión.

Ventas: Presenta una distribución unimodal centrada alrededor de 14 miles de unidades, con una ligera asimetría negativa (-0.19). La ausencia de outliers evidenciada en el boxplot garantiza que el estimador OLS no estará sesgado por observaciones influyentes, resultando en un modelo más robusto.

IV. ANÁLISIS DE CORRELACIÓN

A. Comparación Pearson vs. Spearman

Para caracterizar la relación entre las variables, se calcularon las matrices de correlación de Pearson (r), que mide linealidad, y de Spearman (ρ), que mide asociación monótona, más robusta ante no linealidades. La Fig. 2 muestra los mapas de calor correspondientes.

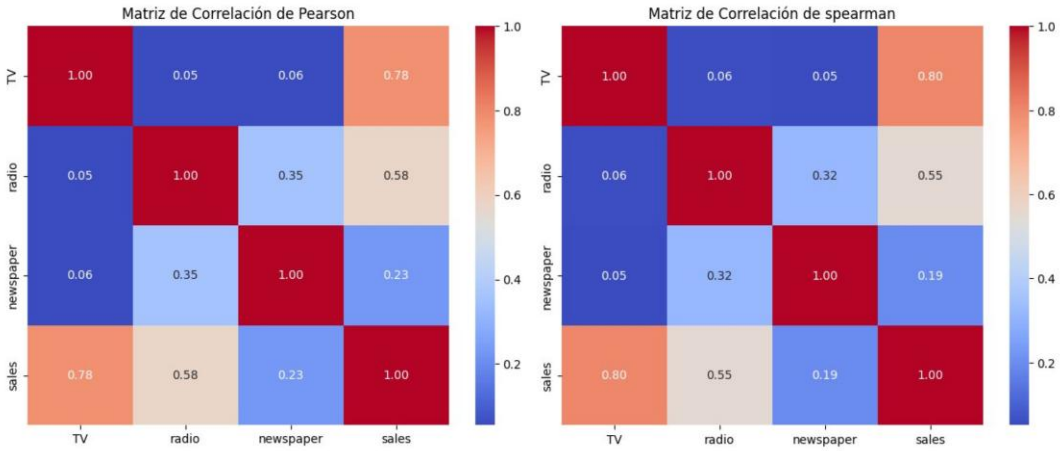

Fig. 2. Matrices de correlación de Pearson (izquierda) y Spearman (derecha).

Los hallazgos más relevantes son:

TV-Ventas: correlación fuerte tanto en Pearson (r=0.78) como en Spearman (rho=0.80), confirmando una relación lineal positiva sólida. La convergencia entre ambos coeficientes indica que la relación es esencialmente lineal, sin distorsiones por valores extremos. Esto justifica el uso de TV como predictor principal en el modelo de regresión simple.

Radio-Ventas: correlación moderada-alta (Pearson r=0.58, Spearman rho=0.55), lo que indica que el Radio es un segundo predictor relevante, aunque menos potente que la TV.

Newspaper-Ventas: correlación débil (Pearson r=0.23, Spearman rho=0.19), anticipando que el periódico aportara poco poder predictivo al modelo múltiple.

TV-Radio: correlación prácticamente nula (r=0.05), señal de baja multicolinealidad. Esta es una condición muy favorable para la regresión múltiple, pues cada predictor aporta información estadísticamente independiente para explicar las ventas.

Radio-Newspaper: correlación moderada (r=0.35), la más alta entre dos predictores. En un análisis de producción se recomienda verificar el Factor de inflación de Varianza (VIF) para descartar multicolinealidad.

B. Análisis Multivariado y Pairplot

La Fig. 3 muestra la matriz de dispersión (pairplot) entre todas las variables de la data set, permitiendo identificar tendencias y distribuciones de forma simultánea.

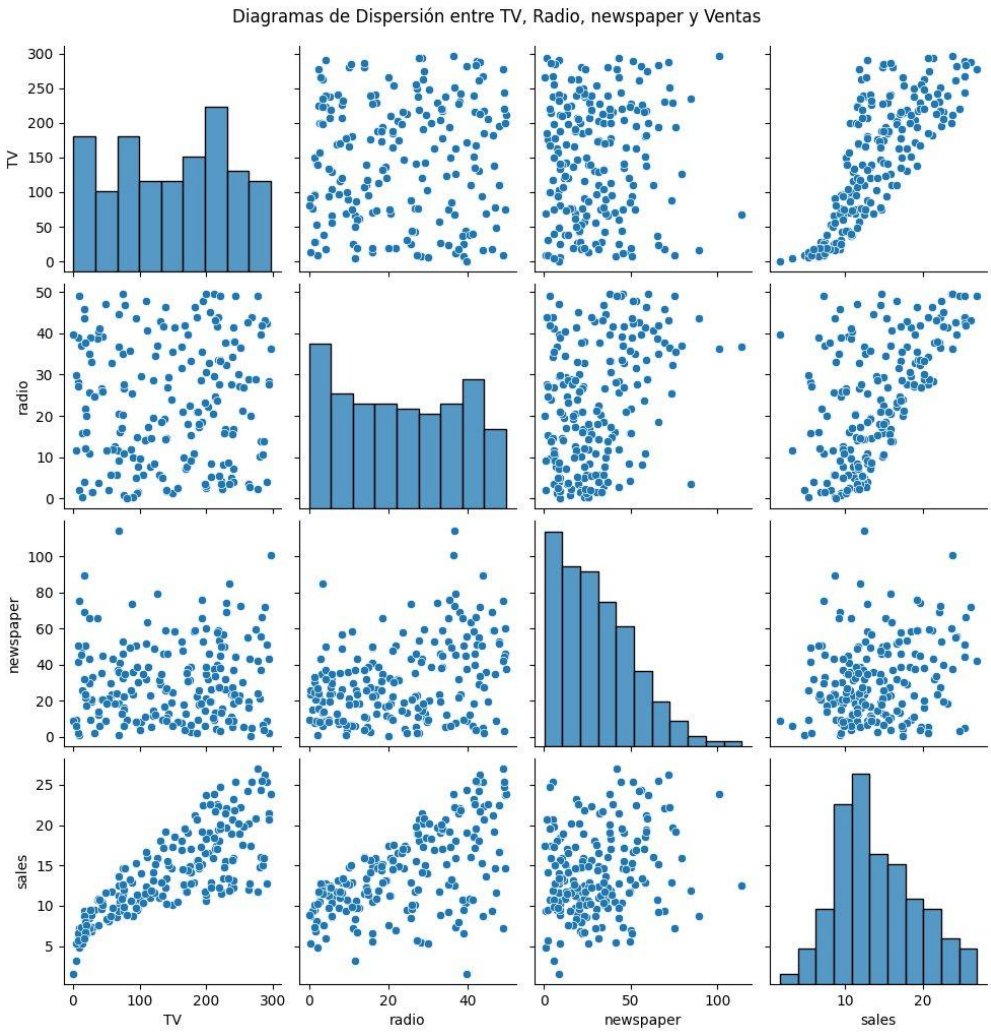

Fig. 3. Pairplot de TV, Radio, Newspaper y Ventas (n=200).

En la diagonal se observan los histogramas individuales de cada variable. TV presenta una distribución aproximadamente uniforme; Radio muestra una distribución concentrada en valores bajos con cola a la derecha; Newspaper exhibe distribución sesgada positivamente con mayor frecuencia en valores bajos; y Ventas muestra una distribución unimodal aproximadamente normal centrada entre 10 y 15 miles de unidades.

Los gráficos fuera de la diagonal confirman: (1) tendencia lineal ascendente muy clara entre TV y Ventas (fila/columna inferior izquierda), con puntos que siguen un patrón curvilínea leve a altos valores de TV; (2) relación positiva moderada entre Radio y Ventas; (3) dispersión aleatoria sin estructura lineal evidente entre Newspaper y Ventas, corroborando su baja correlación (r=0.23); y (4) ausencia de patrones entre TV y Radio, confirmando la baja multicolinealidad entre estos dos predictores clave.

La Fig. 4 complementa este análisis con tres matrices: covarianza, Pearson y Spearman.

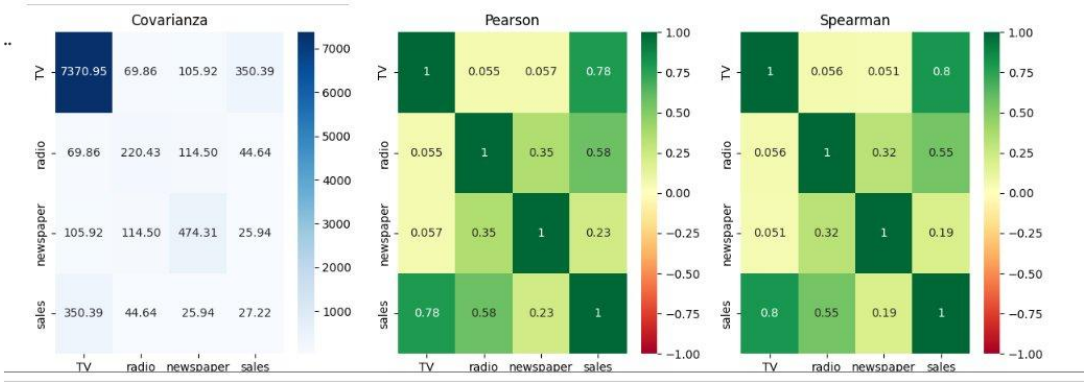

Fig. 4. Matrices de Covarianza, correlación de Pearson y correlación de Spearman.

La matriz de covarianza evidencia que TV tiene la mayor varianza individual (7370.95), seguida por Newspaper (474.31) y Radio (220.43), mientras que Ventas presenta la menor varianza (27.22). La covarianza TV-Ventas (350.39) es la más alta entre pares de variables distintas, reflejando su estrecha relación. En contraste, la covarianza Radio-Ventas (44.64) y Newspaper-Ventas (25.94) son considerablemente menores. Dado que las unidades difieren entre variables, las matrices de correlación estandarizada (Pearson y Spearman) son más adecuadas para comparaciones directas.

V. MODELO DE REGRESIÓN LINEAL SIMPLE

A. Formulación del Modelo

La regresión lineal simple modela la relación entre la inversión en TV (X) y las Ventas (Y) mediante la ecuación:

$$\hat{Y} = \beta_0 + \beta_1 \cdot X + \varepsilon$$

donde β_0 es el intercepto, β_1 es la pendiente, y ε representa el error aleatorio. Los parámetros se estimaron mediante el método de Mínimos Cuadrados Ordinarios (OLS), implementado a través de la clase Linear Regresión de scikit-learn.

B. Resultados y Visualización

Parámetro	Valor
Intercepto (β_0)	7.8055
Pendiente TV (β_1)	0.0446
R^2 (Coef. Determinación)	0.6109
MSE	9.5856
RMSE	3.0961

Tabla III. Resultados del Modelo de Regresión Simple (TV → Ventas)

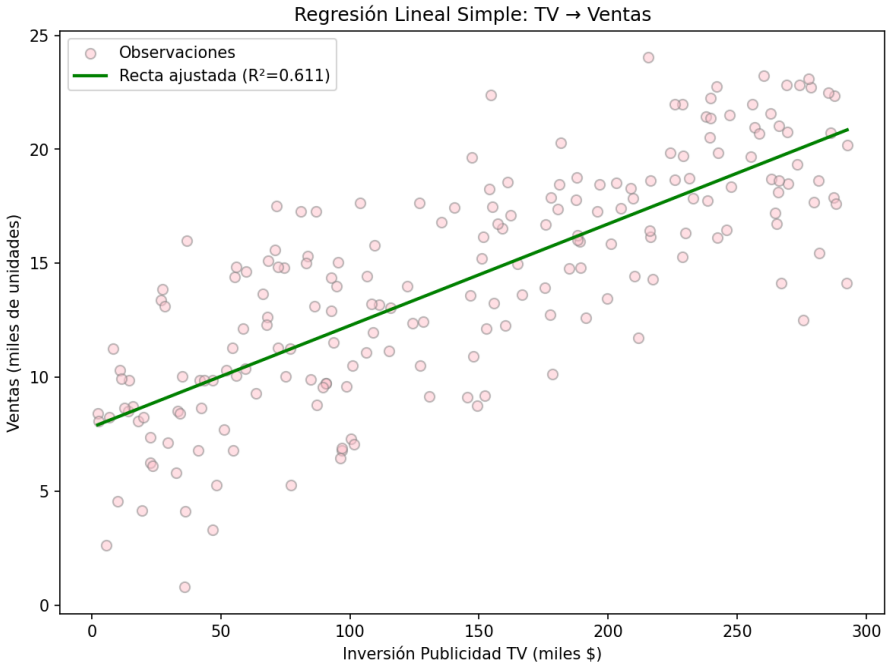

Fig. 5. Diagrama de dispersión con recta de regresión ajustada (R^2=0.611).

C. Interpretación

Intercepto (β_0=7.8055): En ausencia de inversión en TV, se estima que las ventas serían de aproximadamente 7,806 unidades. Este valor tiene interpretación teórica dentro del rango de los datos, aunque la extrapolación fuera del rango experimental debe realizarse con cautela.

Pendiente (β_1=0.0446): Por cada mil dólares adicionales invertidos en publicidad televisiva, las ventas aumentan en promedio 44.6 unidades. Esta relación positiva es estadísticamente significativa, validando la utilidad de TV como predictor.

R^2=0.6109: El modelo explica el 61.1% de la variabilidad en las ventas, lo que representa un ajuste aceptable. Sin embargo, el 38.9% restante no explicado sugiere que otros factores contribuyen al comportamiento de las ventas.

RMSE=3.096: En promedio, las predicciones del modelo se desvían ≈3,096 unidades de las ventas reales. Dado que la media de ventas es 14,219 unidades, esto representa un error relativo de aproximadamente el 21.8%.

Heterocedasticidad: En la Fig. 5 se observa que la dispersión de los residuos tiende a aumentar con los valores de TV (patrón de abanico), sugiriendo presencia de heterocedasticidad. En un análisis de producción, este fenómeno ameritaría aplicar transformaciones logarítmicas o utilizar regresión ponderada por mínimos cuadrados.

VI. MODELO DE REGRESIÓN LINEAL MÚLTIPLE

A. Formulación del Modelo

Se extendió el modelo incorporando los tres predictores disponibles: TV (X_1), Radio (X_2) y Periódico (X_3). La ecuación del modelo múltiple es:

$$\hat{Y} = \beta_0 + \beta_1 \cdot TV + \beta_2 \cdot Radio + \beta_3 \cdot Periódico + \varepsilon$$

El plano de regresión resultante minimiza la Suma de Cuadrados de Residuos (RSS) en el espacio tridimensional TV–Radio–Ventas.

B. Resultados

Parámetro	Valor
Intercepto (beta_0)	2.9389
Coeficiente TV (beta_1)	0.0458

Parámetro	Valor
Coeficiente Radio (beta_2)	0.1885
Coeficiente periódico (beta_3)	-0.0010
R2 (Caer. determinación)	0.8972
RMSE	1.5828

Tabla IV. Resultados del Modelo de Regresión Múltiple

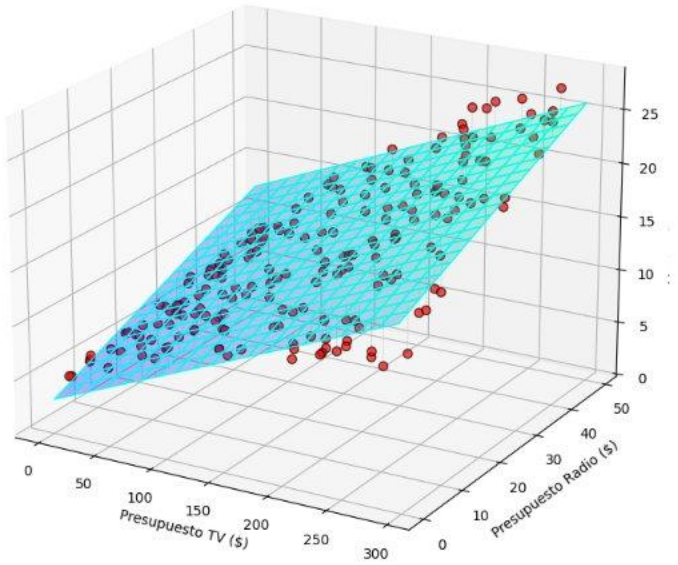

Fig. 6. Plano de regresión múltiple en el espacio TV–Radio–Ventas. Puntos rojos: observaciones reales. Superficie cian: predicciones del modelo. Líneas grises: residuos.

C. interpretación de Coeficientes

beta_0=2.9389: Ventas esperadas si no hay inversión en ningún medio publicitario: aproximadamente 2,939 unidades, lo que representa las ventas base del producto independiente de la publicidad.

beta_1=0.0458 (TV): Manteniendo Radio y periódico constantes, cada $1,000 adicionales invertidos en TV incrementan las ventas en promedio 45.8 unidades. El signo positivo confirma el efecto beneficioso de la publicidad televisiva.

beta_2=0.1885 (Radio): Con TV y periódico fijos, cada $1,000 adicionales en Radio generan aproximadamente 188.5 unidades adicionales de venta. El Radio tiene un impacto marginal por dólar significativamente mayor que la TV (4.1 veces mayor), lo que lo convierte en el canal de mayor retorno de inversión en este data set.

beta_3=-0.0010 (periódico): Coeficiente negativo e insignificante. Al controlar por TV y Radio, el periódico no solo no contribuye positivamente, sino que tiene un efecto marginalmente negativo en las ventas (-1 unidad por cada $1,000 invertidos). Esto sugiere que los mercados con alta inversión en periódico tienden a tener menores ventas una vez descontado el efecto de los otros medios, posiblemente por multicolinealidad residual con Radio (r=0.35). En la práctica, este predictor deben excluirse del modelo.

R2=0.8972: El modelo múltiple explica el 89.7% de la variabilidad en las ventas, una mejora de 28.5 puntos porcentuales respecto al modelo simple (R2=0.6109). Esto confirma que la combinación de los tres medios publicitarios captura de forma mucho más completa los factores determinantes del volumen de ventas.

RMSE=1.583: El error promedio de predicción se reduce de 3.096 a 1.583 unidades, una mejora del 48.8% respecto al modelo simple, traducida en predicciones significativamente más precisas y confiables.

VII. COMPARACIÓN DE MODELOS

La Tabla V resume las métricas de desempeño de ambos modelos, facilitando la comparación directa.

Métrica	Reg. Simple (solo TV)	Reg. Múltiple (TV+Radio+News)	Mejora
R2 (Coef. determinación)	0.6109	0.8972	+28.6 p.p.
MSE	9.5856	2.5052	-73.9%
RMSE (unidades)	3.096	1.583	-48.8%
Predictores	1 (TV)	3 (TV+Radio+News)	+2 vars.

Tabla V. Comparación de Desempeño: Modelo Simple vs. Múltiple

La comparación evidencia que la regresión múltiple ofrece una capacidad predictiva sustancialmente superior, reduciendo el RMSE en un 48.8% y aumentando el R2 en 28.6 puntos porcentuales. Es notable que el coeficiente del periódico resulto negativo (beta_3=-0.0010), lo que justifica explorar un modelo reducido Triado que podría ser más parsimonioso e igualmente preciso. En cualquier caso, habría que evaluar el R2 ajustado y aplicar validación cruzada para verificar la generalización del modelo.

VIII. ARBOLES DE DECISION: FUNDAMENTOS TEORICOS

Un árbol de decisión es un modelo de aprendizaje supervisado de tipo 'caja blanca': a diferencia de redes neuronales, su lógica interna es completamente auditable e interpretable. En el contexto de ingeniería industrial, esta característica es especialmente valiosa para el diagnóstico de causas raíz en procesos productivos.

El árbol estructura sus decisiones mediante cuatro componentes: el Nodo Raiz que contiene el conjunto de datos completo, los Nodos de decisión que representan preguntas sobre variables del proceso (por ejemplo, presión > 225 PSI), las Ramas que bifurcan los datos según la respuesta (verdadero/falso), y los Nodos Hoja que contienen la predicción final. El algoritmo elige automáticamente el orden optimo de las preguntas maximizando la reducción de impureza en cada nivel.

A. métricas de Pureza: entropía e Impureza de Gini

Para arboles de clasificación, el algoritmo necesita cuantificar el 'desorden' de cada nodo. Existen dos métricas principales. La entropía H(S) mide la incertidumbre de un nodo: vale 0 cuando todos los elementos pertenecen a una sola clase (nodo puro) y alcanza su máximo (1.0 en problemas binarios) cuando las clases están perfectamente balanceadas al 50-50. La Ganancia de información IG (S, A) mide la reducción de entropía producida por una partición: el árbol selecciona siempre la variable que maximice esta ganancia, priorizando las preguntas más informativas.

El índice de Gini G = 1 - sum(pi^2) es una alternativa computacionalmente más eficiente. Vale 0 en nodos puros y 0.5 en el caso de máxima impureza binaria. Scikit-learn utiliza Gini por defecto, aunque los resultados prácticos entre ambas métricas suelen ser muy similares. La idea central es la misma: el árbol realiza divisiones que minimizan el Gini (o maximizan la ganancia de entropía), buscando subgrupos lo más homogéneos posible.

métrica	Rango	Valor 0	Valor máximo
entropía H(S)	[0, 1]	Nodo puro (una clase)	Max. desorden (50%-50%)
Gini G	[0, 0.5]	Nodo puro (una clase)	Max. impureza (50%-50%)
Ganancia IG	[0, 1]	Sin mejora en la partición	división perfectamente informativa

Tabla VI. métricas de pureza utilizadas en arboles de decisión.

IX. EJEMPLO 1: ARBOL DE CLASIFICACION EN LINEA DE PRODUCCION

A. descripción del Problema y Dataste Simulado

Se simulo una línea de producción con 300 registros que incluye cuatro variables: maquina (Maquina_A con probabilidad 0.6, Maquina_B con 0.4), presión (distribución normal con media=200 PSI, sigma=25), temperatura (media=80 C, sigma=10) y

turno (Mañana/Tarde). Las reglas ocultas de defecto, que el algoritmo debe descubrir automáticamente, son: Maquina_A + presión > 225 PSI genera producto Defectuoso, y Maquina_B + temperatura < 75 C también genera Defectuoso.

Las variables categóricas (maquina, turno) fueron codificadas mediante one-hot encoding. El Dataset se dividió en 70% entrenamiento y 30% prueba (random_state=42). Para evitar sobreajuste, el árbol fue podado con max_depth=3 y min_samples_leaf=10.

B. Estructura del árbol y Resultados

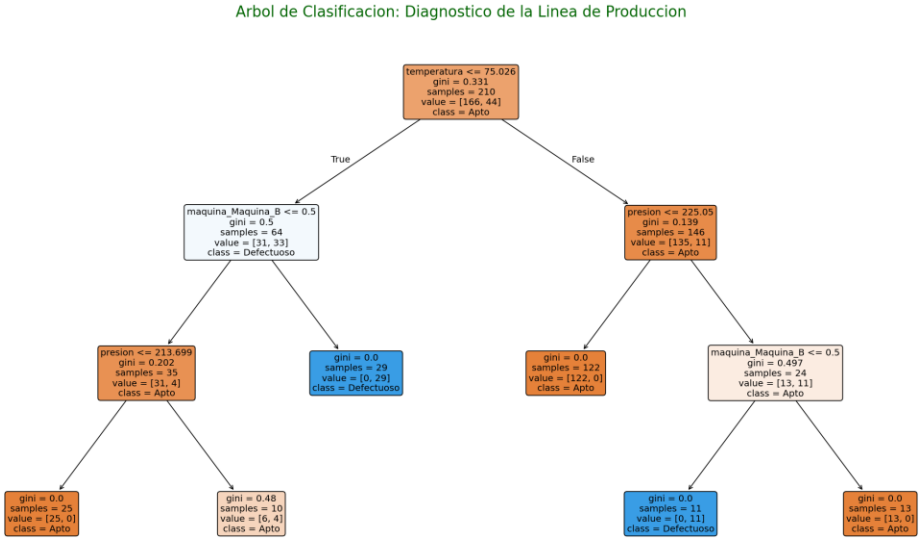

Fig. 7. árbol de clasificación podado (max_depth=3) para diagnóstico de defectos en producción.

El árbol logra una precisión (accuracy) del 98.9% en el conjunto de prueba, confirmando que las reglas aprendidas capturan con alta fidelidad los patrones de defectos del proceso. El Código de colores facilita la interpretación: los nodos naranjas indican predicción 'Apto' y los azules 'Defectuoso', con mayor intensidad de color cuando el Gini se aproxima a 0 (mayor certeza).

El árbol revela la jerarquía causal del proceso: la Temperatura es la primera variable discriminante (nodo raíz). Si temperatura <= 75 C, el riesgo de defectos aumenta drásticamente. Dentro de esa rama, la identificación de Maquina_B con baja temperatura produce un nodo hoja con Gini=0.0 (predicción 100% Defectuoso). Para temperaturas normales, la presión > 225 PSI es el segundo factor de riesgo, donde la Maquina_A es la principal culpable.

Este resultado tiene una interpretación practica directa para ingeniería industrial: no es necesario medir todas las variables simultáneamente. Siguiendo el orden temperatura -> presión -> maquina, se puede diagnosticar el origen del defecto con precisión superior al 98%, optimizando el proceso de inspección.

X. EJEMPLO 2: ARBOL DE REGRESIÓN PARA PREDICCION DE VENTAS

A. Criterio de partición: minimización del MSE

A diferencia del árbol de clasificación, el árbol de Regresión predice valores numéricos continuos. En lugar de minimizar Gini o entropía, el criterio de partición es la minimización del Error cuadrático Medio ponderado:

$$MSE_total = (n_izq/n) * MSE_izq + (n_dern) ** MSE_der$$

El algoritmo evalúa todos los posibles puntos de corte de cada variable (TV<=120, TV<=180, radio<=15, etc.) y selecciona la división que produce el menor MSE_total. La predicción final en cada nodo hoja es el promedio de las ventas de todas las observaciones que llegan a ese nodo.

B. Estructura del árbol y visualización

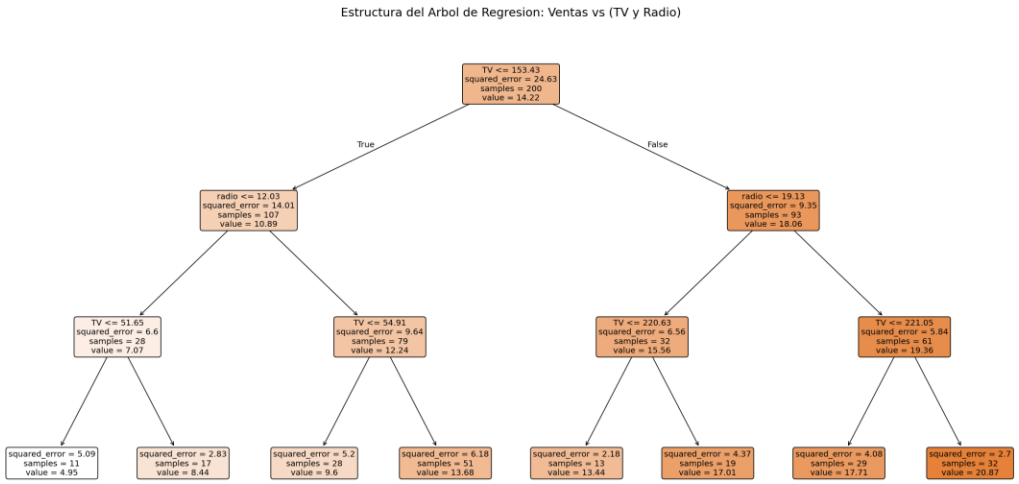

Fig. 8. árbol de regresión (max_depth=3) para predicción de ventas en función de TV y Radio.

El árbol de regresión con profundidad máxima 3 (para evitar sobreajuste) alcanza un R2=0.8213 sobre el conjunto completo. La estructura revela que TV es la primera variable de partición (nodo raíz), confirmando su dominancia como predictor. El Radio aparece en niveles inferiores como variable de refinamiento, ajustando las predicciones dentro de segmentos de TV ya definidos.

C. Importancia de Variables e interpretación

La importancia de variables en el árbol cuantifica la contribución de cada predictor a la reducción total de varianza. Los resultados reales del notebook son: TV con importancia=0.6425 (64.3%) y Radio con importancia=0.3575 (35.8%). Esto contrasta con los coeficientes de la regresión lineal (TV: beta=0.0458, Radio: beta=0.1880), que miden el impacto marginal por unidad.

La diferencia entre las métricas refleja lo que cada modelo captura: la regresión lineal mide el efecto marginal constante por dólar adicional invertido, mientras el árbol mide la jerarquía de decisión, es decir, que variable reduce más la incertidumbre al dividir los datos. Ambas perspectivas son complementarias y no contradictorias para la toma de decisiones estratégicas.

XI. RANDOM FOREST: EL PODER DEL CONSENSO

A. Fundamentos teóricos

El Random Forest es un método de ensamble que combina múltiples arboles de decisión independientes para obtener una predicción más robusta. Utiliza dos mecanismos clave: Bagging (Bootstrap Aggregating), donde cada árbol recibe una muestra aleatoria con reemplazo del dataset original (garantizando perspectivas distintas entre arboles), y selección aleatoria de características, donde en cada nodo el árbol solo puede elegir entre un subconjunto aleatorio de variables (evitando que un predictora dominante como TV opaque a los demas).

La predicción final es el promedio de las predicciones de todos los árboles (en regresión), lo que cancela los errores individuales y captura la tendencia real. Este mecanismo reduce drásticamente la varianza sin aumentar el sesgo, mitigando el sobreajuste que es la principal debilidad de los árboles individuales.

B. Resultados del Modelo con 100 Arboles

Se entreno un Random Forest con n_estimators=100, max_depth=5 y random_state=42, usando TV y Radio como predictores. Los resultados obtenidos fueron:

métrica	Valor
R2 (Coef. determinación)	0.9923
MSE	0.2079
Importancia TV	0.6466 (64.7%)
Importancia Radio	0.3534 (35.3%)

métrica	Valor
N. de árboles (estimadores)	100
Profundidad máxima	5

Tabla VII. Resultados del modelo Random Forest (TV + Radio).

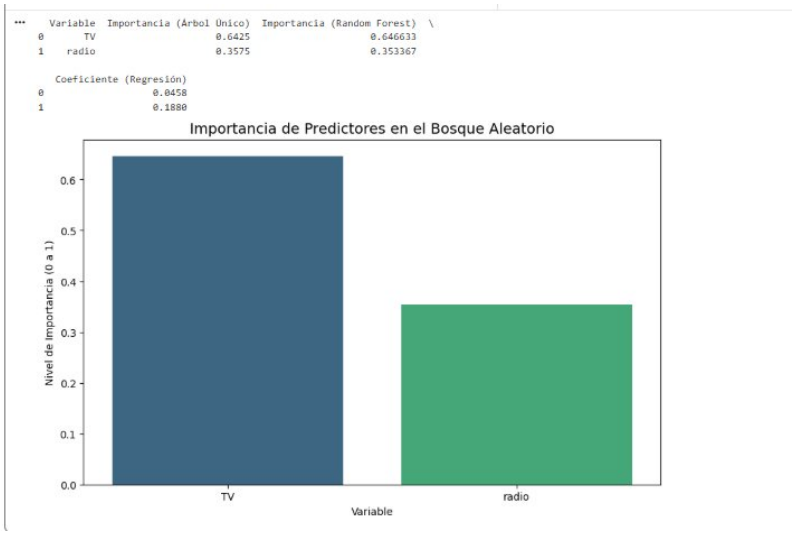

Fig. 9. Importancia de predictores en el Random Forest (grafica original del notebook).

XII. COMPARACION INTEGRAL DE LOS CUATRO MODELOS

Habiendo analizado los cuatro enfoques de modelado (regresión lineal simple, regresión múltiple, árbol de regresión y random forest), es posible realizar una comparación sistemática tanto en términos de capacidad predictiva como de interpretabilidad.

Modelo	R2	RMSE	Predictores	Uso Recomendado
Reg. Lineal Simple	0.6109	3.096	TV	Baseline / análisis marginal
Reg. Lineal múltiple	0.8972	1.583	TV+Radio+News	ROI marginal por canal
árbol de regresión	0.8213	2.098	TV+Radio	explicación / segmentación
Random Forest	0.9923	0.456	TV+Radio	predicción en producción

A. Veredicto estratégico por Objetivo

Random Forest para predicción: Con R2=0.9923 y MSE=0.2079, es el modelo de mayor precisión por amplio margen. Su robustez frente a sobreajuste y valores atípicos lo convierte en el candidato ideal para implementación en producción cuando el objetivo es pronosticar ventas futuras con la máxima fiabilidad posible.

árbol de decisión para explicación: Con R2=0.8213, sacrifica algo de precisión a cambio de interpretabilidad total. Su estructura visual es ideal para presentaciones ejecutivas y para comunicar las reglas de decisión a equipos no técnicos.

Regresión Lineal para análisis marginal: Proporciona coeficientes directamente interpretables en términos económicos (cuanto aumentan las ventas por cada dólar adicional invertido), siendo la herramienta más adecuada para el cálculo del ROI y la justificación de presupuestos publicitarios.

conclusión estrategia: Los cuatro modelos no compiten entre sí; se complementan. Un flujo de trabajo optimo utiliza la regresión lineal para entender el impacto marginal, el árbol de decisión para comunicar la jerarquía de variables, y el Random Forest para las predicciones operativas de máxima precisión.

XIII. CONCLUSIONES GENERALES

1. Calidad del Dataset: El dataset Advertising es de alta calidad, sin valores faltantes, con variables numéricas bien definidas. La distribución uniforme de TV y la distribución aproximadamente normal de Ventas son condiciones favorables para todos los modelos analizados.

2. jerarquía de correlaciones: TV es el predictora dominante (Pearson r=0.782, Spearman rho=0.801), seguido por Radio (r=0.576) y Newspaper (r=0.228). La baja correlación TV-Radio (r=0.055) garantiza independencia estadística entre los principales predictores.

3. Regresión simple (línea base): El modelo TV->Ventas (R2=0.611, RMSE=3.096) establece la referencia. La pendiente beta_1=0.0458 indica 45.8 unidades adicionales de venta por cada $1,000 en TV.

4. Regresión múltiple (mejor modelo lineal): Al incorporar Radio y Newspaper, el R2 sube a 0.8972 y el RMSE cae a 1.583. El Radio tiene el mayor retorno marginal (beta_2=0.1885). El periódico con beta_3=-0.0010 deben excluirse del modelo final.

5. árbol de clasificación: Con 98.9% de precisión en el Dataset de producción simulado, demuestra que los árboles de decisión son herramientas poderosas para diagnóstico de causas raíz en ingeniería industrial, descubriendo automáticamente las reglas: Temperatura <= 75 C y Maquina_B es causa raíz de defectos.

6. árbol de regresión: Con R2=0.8213 usando solo TV y Radio, ofrece interpretabilidad completa a cambio de algo de precisión. La importancia TV=64.3% y Radio=35.8% define la jerarquía de decisión del modelo.

7. Random Forest (modelo de mayor precisión): Con R2=0.9923 y MSE=0.2079, supera a todos los modelos anteriores usando los mismos dos predictores. La importancia de TV (64.7%) es prácticamente idéntica a la del árbol único (64.3%), confirmando la alta consistencia entre modelos basados en árboles. El extraordinario R2=0.9923 posiciona al Random Forest como la herramienta de referencia para predicción operativa.

8. Trabajo futuro: Se recomienda: (a) validación cruzada k-fold para estimar la generalización real de todos los modelos; (b) ajustar un modelo de regresión TV+Radio sin Newspaper para comparar con el modelo múltiple completo; (c) explorar términos de interacción TV*Radio en la regresión; (d) aplicar Gradient Hosting (XGBoost, LightGBM) para comparar con el Random Forest; y (e) analizar los residuos con pruebas formales de homocedasticidad (Bruch-Pagan).

REFERENCIAS

[1] G. James, D. Witten, T. Hastie, and R. Tibshirani, An Introduction to Statistical Learning with Applications in R, 2nd ed. New York, NY: Springer, 2021.

[2] F. Pedregosa et al., Scikit-learn: Machine learning in Python, Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.

[3] W. McKinney, Data Structures for Statistical Computing in Python, in Proc. 9th Python in Science Conf., 2010, pp. 51-56.

[4] J. D. Hunter, Matplotlib: A 2D graphics environment, Computing in Science & Engineering, vol. 9, no. 3, pp. 90-95, 2007.

[5] M. Waskom, Seaborn: statistical data visualization, Journal of Open Source Software, vol. 6, no. 60, p. 3021, 2021.